

➤ 考试时间


2025年1月7日（星期二） 18:30–20:10


➤ 考试题型

- 选择题
- 大题：算法描述、计算、证明

商务智能系统架构

商务智能系统的架构





商务智能系统主要部分（1）

➤ 数据源与数据获取

- 数据通常包括企业内部数据与外部数据。
- **内部数据**：企业各种应用系统、办公室自动化系统等产生的业务数据、文档等。
- **外部数据**：市场、竞争对手的数据以及各类外部统计数据等。
- 业务数据需要经过数据评价、数据筛选以及**ETL（数据抽取、转换、装载）**后才可存储在数据仓库中。

商务智能系统主要部分（1）

➤ 数据存储与管理

- 数据库(Database)：计算机系统用来存储、搜索、检索和分析信息的有组织的存储。数据库有多种类型，如关系数据库。关系数据库将信息存储在由行和列组成的表中。不同表中的数据通过称为键的唯一标识符进行连接。
- 数据集市(Data Mart)：一种数据存储系统，其中包含特定于组织业务部门的信息。它包含公司存储在更大存储系统中的一小部分选定数据。公司使用数据集市更高效地分析特定于部门的信息。
- 数据仓库(Data Warehouse)：是一个庞大的数据库系统，用于存储整个企业的信息。它从各种来源收集原始信息，并将其处理为以表格格式存储的结构化数据。

➤ 可以使用数据集市来检索和分析信息。而数据库则可收集、管理和存储信息。可以使用工具对存储的信息进行处理、格式化并将其传输到数据集市。数据仓库包含有关各种主题的企业范围的数据。而数据集市则存储与特定主题密切相关的信息。

商务智能系统主要部分（2）

➤ 访问工具

访问工具包括应用接口和中间件服务器。数据库中间件允许用户透明地访问数据仓库服务器，即用于**即席查询**（ad-hoc query）、在线分析处理和数据挖掘。

➤ 决策支持工具

决策支持工具由**即席查询、报表、在线分析处理（OLAP）和数据挖掘**等工具组成。

商务智能系统主要部分（3）

➤ 商务智能应用

利润成本分析、资产分析、营销分析、投资组合分析以及人力资源管理、顾客关系管理、供应链管理等各种业务的分析。

➤ 系统管理

系统安全管理（用户身份验证和权限管理）、元数据的管理与更新、数据仓库的日常维护与监控、数据使用审计和容量规划等。



➤ 元数据管理

对开发、管理数据仓库时所用的技术元数据和支持业务人员的业务元数据的管理。

业务数据分析的类型

➤ 数据分析技术的发展可分为：

报表查询、在线分析处理（OLAP）和数据挖掘等阶段。




事务型处理

- **事务型处理**：即操作型处理，是指对数据库的联机操作处理OLTP。事务型处理是用来协助企业对响应事件或事务的日常商务活动进行处理。它是事件驱动、面向应用的，通常是对一个或一组记录的增、删、改以及简单查询等（**大量、简单、重复和例行性**）。例如订单处理、库存管理、用户管理等。
- 在事务型处理环境中，数据库要求能支持日常事务中的大量事务，**用户对数据的存取操作频率高，但每次操作处理的时间短。**

分析型处理

- 分析型处理：用于管理人员的决策分析，例如决策支持系统（DSS）、经理信息系统（EIS） 和 多维分析等。它帮助决策者分析数据以观察趋向、判断问题。
- 分析型处理经常要访问大量的历史数据，支持复杂的查询。
- 分析型处理过程中经常用到外部数据，这部分数据不是由事务型处理系统产生的，而是来自于其他外部数据源。



分析型处理

➤ 事务型处理和分析型处理具有不同的特征，主要体现在以下几个方面：

- 处理性能
- 数据集成
- 数据更新
- 数据时限
- 数据综合

事务型处理数据与分析型处理数据的区别

特性	OLTP	OLAP
特征 面向 用户 功能 DB 设计 数据 汇总 视图 工作单位 存取 关注 操作 访问记录数 用户数 DB规模 优先 度量	操作处理 事务 办事员、DBA、数据库专业人员 日常操作 基于E-R，面向应用 当前的；确保最新 原始的，高度详细 详细，一般关系 短的、简单事务 读/写 数据进入 主关键字上索引/散列 数十个 数千 100MB到GB 高性能，高可用性 事务吞吐量	信息处理 分析 知识工人（如经理、主管、分析员） 长期信息需求，决策支持 星形/雪花，面向主题 历史的；跨时间维护 汇总的，统一的 汇总的，多维的 复杂查询 大多为读 信息输出 大量扫描 数百万 数百 100GB到TB 高灵活性，端点用户自治 查询吞吐量，响应时间

数据仓库（Data Warehouse）


- 数据仓库用来保存从多个数据库或其它信息源选取的数据，并为上层应用提供统一用户接口，完成数据查询和分析。支持整个企业范围的决策支持，提供大量面向整个企业的综合信息。
- 数据仓库是作为决策服务的分析型数据库，用来存放大容量的只读数据，为制定决策提供所需要的信息。
- 数据仓库是与业务系统相分离的、基于标准企业模型集成的、带有时间属性的、面向主题及不可更新的数据集合。

数据仓库的特点

- 面向主题
- 集成性
- 数据的非易失性
- 数据的时变性

数据仓库的结构

- 数据仓库主要包括数据的提取、转换与装载（ETL）、元数据、数据集市和操作数据存储等部分，常用的数据仓库结构如下图。



数据仓库系统的组成

- 源数据：数据仓库中的数据来源于多个数据源，它不仅可以是企业内部的关系型数据库，还包括非传统数据，如文件、HTML文档等。
- 数据仓库管理系统：
 - 元数据库及元数据管理部件：元数据库用来存储由定义部件生成的关于源数据、目标数据、提取规则、转换规则以及源数据与数据仓库之间的映射信息等。
 - 数据转换部件：该部件把数据从源数据中提取出来，依定义部件的规则将不同数据格式的源数据转换成数据仓库的数据格式并装载进数据仓库。
 - 数据集成部件：该部件根据定义部件的规则、统一各源数据的编码规则，并净化数据，根据元数据中定义的数据组织形式对数据进行汇总、聚合计算。
 - 数据仓库管理部件：它主要用于维护数据仓库中的数据，备份、恢复数据以及管理数据的安全权限问题。

数据仓库系统的组成


➤ 数据仓库前端工具集

- 查询/报表工具：以图形化方式和报表方式显示数据，帮助了解数据的结构、关系以及动态性。
- OLAP工具：通过对信息的多种可能的观察形式进行快速、一致和交互性的存取，便于用户对数据进行深入的分析。
- 数据挖掘工具：从大量数据中挖掘出具有规律性的知识，以及数据之间的内在联系。
- 前端开发工具：提供用户编程接口，便于在现有系统的基础上进行二次开发，增强系统的伸缩性。

➤ 数据仓库：在数据仓库系统中，数据仓库是一个数据存储集合，它的存储形式通常有多维数据库、关系型数据库及其他存储方式。

数据集市

- 数据仓库是企业级的，能为整个企业各部门的运行提供决策支持手段。而数据集市（Data Mart）是部门级别的，一般只能为某个局部范围内的管理人员服务，也称为部门级的数据仓库。
- 数据集市有两种：独立的数据集市和从属的数据集市。
- 数据集市是专门为某一部门或某个特定的商业需求定制的，而不是根据数据容量命名的。
- 数据集市不是数据仓库，也并非小的数据仓库，多个数据集市集合并不简单构成数据仓库。



元数据

- 数据仓库中的元数据是关于数据仓库中数据的数据，作用类似于数据库管理系统的数据字典，用于保存逻辑数据结构、文件、地址和索引等信息。
- 数据仓库的所有数据都要通过元数据来管理和控制。元数据是用来描述数据的数据，它描述关于源数据的说明，包括源数据的来源、源数据的名称、源数据的定义、源数据的创建时间等对源数据进行管理所需要的信息，也可反映数据仓库中的数据项是从哪个特定的数据源填充的，经过哪些转换、集成过程。
- 用户在使用数据仓库时，通过元数据访问数据，明确数据项的含义以及定制报表。
- 数据仓库的规模及其复杂性离不开正确的元数据管理，包括增加或移除外部数据源，改变数据清洗方法、控制出错的查询以及安排备份等。

技术元数据与业务元数据

➤ 元数据可分为技术元数据与业务元数据。

➤ 技术元数据

技术元数据为开发和管理数据仓库的IT人员使用，描述与数据仓库开发、管理和维护相关的数据，包括数据源信息、数据转换描述、数据仓库模型、数据清洗与更新规则、数据映射和访问权限等。

➤ 业务元数据

业务元数据为管理层和业务分析人员服务，从业务角度描述数据，包括商务术语、数据仓库中有什么数据、数据的位置和数据的可用的性等，使业务人员更好地理解数据仓库中哪些数据是可用的以及如何使用它们。

元数据的作用

- 描述哪些数据在数据仓库中，帮助决策分析者对数据仓库中的数据定位。
- 定义数据进入数据仓库的方式，作为数据汇总、映射和清洗的指南。
- 记录业务事件的发生和随之进行的数据抽取的时间安排。
- 记录并检测系统数据一致性的要求和执行情况。
- 评估数据质量。

ETL


- 数据仓库并非只是数据的简单累积，而是要经过一系列的抽取、转换和装载的过程，即ETL。
- ETL是构建数据仓库的重要环节，也是企业数据管理的核心，对数据仓库的后续环节影响大。
- ETL的主要功能分为数据抽取、数据转换、数据清洗以及数据装载。

数据清洗

- 数据源中数据的质量是非常重要的，低劣的“脏”数据容易导致低质量的决策甚至是错误的决策。此外，这些“脏”数据或不可用数据也可能造成报表的不一致等问题。因此有必要全面校验数据源的数据质量，此过程就是数据清洗(data cleaning)。
- 主要的數據質量問題有以下几种：
 - 缺失(missing)数据：即数据值的缺失。
 - 错误数据：常见的错误数据包括字段的虚假值、异常取值等。这些错误数据产生的主要原因是由于业务系统在数据输入后不能进行正确性判断而被录入数据库，错误数据需要被及时找出并限期修正。
 - 数据重复：数据重复是反复录入同样的数据记录，这类数据会增加数据分析的开销。
 - 数据冲突：数据冲突包括同一数据源内部的数据冲突和多个数据源之间的数据冲突，冲突的数据也需要及时地修正。

操作数据存储（ODS）

- 数据仓库实现操作型数据与分析型数据的分离，建立了数据库-数据仓库（DB-DW）两层体系结构。然而DB-DW并不能完全满足企业所有的数据处理需求，有时企业需要全局一致的、细粒度、面向主题、集成的和时变的当前或接近当前的数据，因而需要在DB-DW之间增加一个新的层次——操作数据存储，构建DB-ODS-DW结构，满足实时或近实时的查询要求和报表需求。
- 操作数据存储也称为实时数据仓库。




操作型数据库、操作数据存储和数据仓库之间的比较

比较项目	操作型数据库	操作数据存储	数据仓库
数据内容	当前值	当前和最近的值	存档、归纳数据和经计算得出的数据
数据组织	面向应用程序	有主题域,数据集成	面向主题
数据性质	动态(经常变化)	动态(经常变化)	静态(刷新除外)
数据结构	适于操作型计算	较复杂	适于决策分析
访问频率	高	高到中	中到低
数据更新	按字段更新	联机可变,数据更新频率比较高	一般不修改,更新时间长
数据访问	少量记录/事务	少量记录/事务	大量记录/事务
用途	高度结构化、重复处理和事务处理	高度结构化、重复处理和事务处理	分析处理
对响应时间的要求	通常少于 5s	通常少于 5s	几秒钟到几分钟,有时几小时
对性能的要求	高	高到中	中


数据仓库模型

- 概念模型
- 逻辑模型
- 物理模型

面向用户的需求




更详细的技术细节



- 概念模型
- 逻辑模型
- 物理模型


OLAP简介—基本概念（1）

- **变量：**变量是数据度量的指标，是数据的实际意义。
 - 图中的数据“560”本身并没有意义，但如果描述2007年第一季度大中华区 LCD 的销售量是560 万台，则数据“560”就有了实际意义，代表了产品销售量的度量。
 - 年、季度和月份是描述时间的三个层次，10万是变量“销售额”的值。通常也把变量称为度量。



OLAP简介—基本概念

- **维**：维是与业务主题相关的一组属性，单个属性或属性集合可以构成一维。
- 例如计算机配件销售随着时间推移而产生的变化，这是从时间的角度对产品的销售进行观察。
 - 如果把一个主题的多种属性定义为多个维，那么用户就能够从多个角度组合分析销售情况。如图所示，可以从时间维、产品维和地区维分析销售量。



OLAP简介—基本概念

- **维的层次：**一个维往往可以具有多个层次，例如时间维分为年、季度、月和日等层次，地区维可以分为国家、地区、省、市等层次。这里的层次表示数据细化程度，对应概念分层，后面提到的上钻操作就是由低层概念映射到较高层概念。概念分层除了根据概念的全序和偏序关系确定外，还可以通过对数据进行离散化或分组来实现。
- **维的成员：**维是多层次的，不同层次的取值构成一个维成员，例如，“某年某季度”、“某季度某月”等都可以是时间维的成员。


OLAP简介—基本概念

- **多维数组：**多维数组用维和度量的组合表示一个多维数组，可以表示为（维1，维2，…，维n，度量）
 - 例如（月份，地区，产品，销售额）组成一个多维数组。
- **数据单元（单元格）：**多维数组的取值
 - 当多维数组中每个维都有确定的取值时，就唯一确定一个变量的值。
 - 数据单元可以表示为（维1成员，维2成员，……，维n成员，度量值）。例如（2007年第一季度，大中华区，LCD，560万台）表示一个数据单元，表示2007 年第一季度大中华区LCD产品销售560万台。

OLAP简介—基本概念

➤ **事实：**事实是不同维度在某一取值下的度量。

- 例如：2007年第一季度 LCD 在大中华区的销售额是560万台就表示在时间、产品和地区三个维度上企业销售事实的度量，同时包含时间维度的两个层次：年和季度。有关销售的多维分析视图如图所示。



OLAP简介——OLAP的特点

- OLAP的多维性、层次、维度计算以及结构与视图的分离等特点
 - 电子数据表不具备上述特点
- 快速
- 可分析
- 共享
- 多维

OLAP简介——OLAP的定义

- OLAP是一种共享多维信息的快速分析技术；OLAP利用多维数据库技术使用户可以从不同角度观察数据；OLAP用于支持复杂的分析操作，侧重对管理人员的决策支持，可以满足分析人员快速、灵活地进行大数据量的复杂查询的要求，并且以一种直观易懂的形式呈现查询结果，辅助决策；OLAP是针对特定问题的在线数据访问和分析；OLAP是通过对信息的多种可能的观察形式进行快速、稳定一致和交互性的存取，允许管理人员对数据进行深入观察。
- 上面定义从各个角度对在线分析处理给予了不同的解释，OLAP 委员会（OLAP Council）则给出了较为正式和严格的定义：在线分析处理是使管理人员能够从多种角度对从原始数据中转化出来的、能够真正为用户所理解的并真实反映业务特性的信息进行快速、一致和交互的存取，从而获得对数据更深入的理解。

OLAP简介——OLAP的特点

- OLAP的多维性、层次、维度计算以及结构与视图的分离等特点
 - 电子数据表不具备上述特点
- 快速
- 可分析
- 共享
- 多维

OLTP与OLAP的区别



- 在线事务处理是事件驱动、面向应用的，其主要特点是性能要求高，用户数量大。
- 在线分析处理则支持复杂的分析，侧重于为管理人员提供决策支持，并以直观的形式呈现结果。
- 在线事务处理与在线分析处理的主要区别如表所示。

项目	OLTP	OLAP
用户	业务人员、DBA、数据库专业人员	经理、主管、数据分析师
特征	面向事务、操作处理	面向分析、信息处理
功能	日常操作处理	长期信息需求、决策支持
DB 设计	基于 E-R、面向应用	星型或雪花、多维结构、面向主题
数据	当前的、最新的、细节的、二维的、孤立的	历史的、聚合的、多维的、集成的、统一的
视图	详细	聚合的、多维的
存取规模	读/写 数十(甚至数百)条记录、可更新	大多为读 上百万(甚至上亿)条记录,不可更新,周期性刷新
操作单位	简短的事务	复杂的查询
访问记录	主关键字上索引、数十次	大量扫描、数百万次
用户数	数百个~数千、数万个	数个~数百个
DB 大小	100MB~100GB	100GB~100TB
优先	高性能、高可用性	高灵活性、用户可定制、高性能
衡量标准	事务吞吐量	查询吞吐量、响应时间

OLAP操作

- 在线分析处理比较常用的操作包括切片（slice）与切块（dice）、上钻（drill-up）与下钻（drill-down）旋转（rotate）、钻过、钻透等。在线分析处理还能对多维数据进行深加工。
- 在线分析处理的这些操作使用户从多个视角观察数据，并以图形、报表等多种形式表示，从而获取隐藏在数据中的信息。


OLAP操作实例—多维数据

性别	年龄	月收入			
		无	较低	中档	较高
女	16岁以下	6.3	0.9	2.3	1.6
	16~20岁	16.1	3.5	0.8	1.6
	21~25岁	29.3	28.1	29.7	19.0
	26~30岁	15.7	22.7	27.3	25.4
	31~35岁	9.6	12.2	18.8	14.3
	36~40岁	9.5	12.8	8.6	14.3
	40岁以上	13.5	19.8	12.5	23.8

性别	年龄	月收入			
		无	较低	中档	较高
女	16 岁以下	6.3%	0.9%	2.3%	1.6%
	16~20 岁	16.1%	3.5%	0.8%	1.6%
	21~25 岁	29.3%	28.1%	29.7%	19.0%
	26~30 岁	15.7%	22.7%	27.3%	25.4%
	31~35 岁	9.6%	12.2%	18.8%	14.3%
	36~40 岁	9.5%	12.8%	8.6%	14.3%
	40 岁以上	13.5%	19.8%	12.5%	23.8%
男	16 岁以下	6.6%	1.0%	2.9%	1.5%
	16~20 岁	29.0%	5.5%	5.8%	5.9%
	21~25 岁	34.8%	36.1%	32.0%	25.0%
	26~30 岁	15.0%	29.0%	27.2%	30.9%
	31~35 岁	6.6%	12.6%	15.5%	23.5%
	36~40 岁	2.9%	5.7%	4.9%	8.8%
	40 岁以上	5.1%	10.1%	11.7%	4.4%

OLAP操作实例—切片与切块

- 切片和切块：选定多维数组的1维成员做数据分割的操作称为该维上的一个切片。
- 在服装消费实例分析中，对“性别、年龄、月收入”三维立方体选取年龄段进行切片，可得到26-30岁年龄段不同月收入人群中男女消费者的购买信息。



OLAP操作—切片与切块

- 常把多维数组中选定一个三维子集的操作视为切块。图所示为多维数组选取年龄段21-30岁进行切块，可得到此年龄段不同月收入下男女消费者的购买情况（性别， 21-30岁， 月收入， 购买百分比）。

		男			
		34.8	36.1	32.0	25.0
		女			
		29.3	28.1	29.7	19.0
21~25岁		29.3	28.1	29.7	19.0
26~30岁		15.7	22.7	27.3	25.4
		无 较低 中档 较高			

OLAP操作—切片与切块

- 当某维只取一个维成员时，便得到一个切片，而切块则是某一维取值范围下的多个切片的叠合。通过对立方体的切片或切块分割，可以从不同视角得到各种数据，包括各个年龄段下女性顾客在不同月收入下的服装购买情况，或者是中档收入下不同年龄段的购买情况。
- 切片与切块的作用是对数据进行过滤，使用户专注于局部信息。

OLAP操作—钻取

- **上钻：**上钻又称上卷 roll-up，上钻操作是指通过一个维的概念分层向上攀升或者通过维归约在数据立方体上进行数据汇总。例如，在服装购买顾客调查中，可以按月收入分段汇总数据，把较低、中档与较高归约为“有收入”，便可以得到沿月收入维上钻的数据汇总；也可以按年龄分段汇总数据，把16岁以下与16-20岁归约为“青少年”，21-25岁、26-30岁与31-35岁归约为“青年”，36-40岁与40岁以上归约为“中老年”，从而得到沿年龄段维上钻的数据汇总视图。


年龄	性别	月收入			
		无	较低	中档	较高
16岁以下	男	6.6	1.0	2.9	1.5
	女	6.3	0.9	2.3	1.6
16~20岁	男	6.3	0.9	2.3	1.6
	女	16.1	3.5	0.8	1.6
21~25岁	男	29.3	28.1	29.7	19.0
	女	15.7	22.7	27.3	25.4
26~30岁	男	9.6	12.2	18.8	14.3
	女	9.5	12.8	8.6	14.3
31~35岁	男	13.5	19.8	12.5	23.8
	女	13.5	19.8	12.5	23.8




年龄段	性别	月收入			
		无	较低	中档	较高
青少年	男	35.6	6.5	8.7	7.4
	女	22.4	4.4	3.1	3.2
青年	男	22.4	4.4	3.1	3.2
	女	54.6	63	75.8	58.7
中老年	男	23	32.6	21.1	38.1
	女	23	32.6	21.1	38.1

OLAP操作—钻取

- **下钻：**下钻是上钻的逆操作。通过对某一汇总数据进行维层次的细分。下钻使用户对数据能够获得更深入的了解，更容易发现问题的本质，从而做出正确的决策。钻取使用户不会被海量的数据搞得晕头转向：上钻使用户可以站在更高层次观察数据，下钻则可以细化到用户所关心的详细数据。钻取的深度与维所划分的层次相对应，根据用户关心的数据粒度来合理划分。



性别	年龄	月收入			
		无	较低	中档	较高
青少年	男	22.4	4.4	3.1	3.2
	女	35.6	6.5	8.7	7.4
	合计	57.8	10.9	11.8	10.6
青年	男	54.6	63	75.8	58.7
	女	22.4	4.4	3.1	3.2
	合计	77.0	67.4	78.9	61.9
中老年	男	23	32.6	21.1	38.1
	女	58.7	79.4	13.2	7.4
	合计	81.7	112.0	34.3	45.5



性别	年龄	月收入			
		无	较低	中档	较高
16岁以下	男	6.6	1.0	2.9	1.5
	女	6.3	0.9	2.3	1.6
	合计	12.9	1.9	5.2	3.1
16~20岁	男	16.1	3.5	0.8	1.6
	女	29.3	28.1	29.7	19.0
	合计	45.4	31.6	30.5	20.6
21~25岁	男	15.7	22.7	27.3	25.4
	女	9.6	12.2	18.8	14.3
	合计	25.3	34.9	46.1	39.7
26~30岁	男	9.5	12.8	8.6	14.3
	女	13.5	19.8	12.5	23.8
	合计	23.0	32.6	21.1	38.1
31~35岁	男	6.3	0.9	2.3	1.6
	女	16.1	3.5	0.8	1.6
	合计	22.4	4.4	3.1	3.2
36~40岁	男	35.6	6.5	8.7	7.4
	女	22.4	4.4	3.1	3.2
	合计	58.0	10.9	11.8	10.6
40岁以上	男	54.6	63	75.8	58.7
	女	23	32.6	21.1	38.1
	合计	77.6	95.6	96.9	96.8

OLAP操作—旋转

- **旋转**又称为转轴 (pivot)，它通过旋转变换一个报告或页面显示的维方向，在表格中重新安排维的放置，如行列互换。这种对立方体的重定位可以得到不同视角的信息。

月收入	性别	年龄						
		16岁以下	16~20岁	21~25岁	26~30岁	31~35岁	36~40岁	40岁以上
无	男	6.6	29.0	34.8	15.0	6.6	2.9	5.1
	女	6.3	16.1	29.3	15.7	9.6	9.5	13.5
	无	6.3	16.1	29.3	15.7	9.6	9.5	13.5
	较低	0.9	3.5	28.1	22.7	12.2	12.8	19.8
中档	无	2.3	0.8	29.7	27.3	18.8	8.6	12.5
	较高	1.6	1.6	19.0	25.4	14.3	14.3	23.8

OLAP操作—其他OLAP操作

除以上常用的多维操作外，还有其他多维操作：

- **钻过 (drill-across)**：钻过操作涉及多个事实表的查询并把结果合并为单个数据集，一个典型的例子就是预测数据与当前数据的结合。通常预测数据与当前数据存在于不同的表中，当用户比较预测销售与当前销售时，需要跨多个事实表查询。
- **钻透 (drill-through)**：钻透使用SQL，查询到数据立方体的底层，一直到后端的关系表。

OLAP的分类—按照处理方式

- 按照处理方式分类是指OLAP按照数据处理的地点可以分为服务器端在线分析处理（Server-side OLAP 或 Server OLAP）和客户端在线分析处理（Client-side OLAP 或 Client OLAP）。
- **Server OLAP:** 绝大多数 OLAP 系统都属于此类，Server OLAP 在服务器端的数据库上建立多维数据立方体，由服务器端提供多维分析，并把最终结果呈现给客户端。
- **Client OLAP:** 与服务器端在线分析处理相反，Client OLAP 把相关立方体数据下载到本地，由本地为用户提供多维分析，从而保证在出现网络故障时仍然能正常工作。这类 OLAP 产品往往轻便、简洁。例如，Cognos（IBM）的 Powerplay 产品提供了简洁部署且具有交互性的 PowerPlay Web Explorer界面，其他代表产品还有Brio Designer等。

OLAP的分类—按照存储方式

➤ OLAP 按照存储器的多维数据存储方式可以分为：

- (1) 关系在线分析处理 (Relational OLAP, ROLAP)
- (2) 多维在线分析处理 (Multi-dimensional OLAP, MOLAP)
- (3) 混合在线分析处理 (Hybrid OLAP, HOLAP)

探索性数据分析常用的统计图

- 不同类型的变量：柱状图、直方图、箱线图、折线图、散点图、热力图、平行坐标系图
- 横纵轴的定义
- 各个统计图的功能



SVD、PCA和MDS的原理和计算方法

奇异值分解 (SVD)

符号定义

$$A = U\Sigma V^T = u_1\sigma_1v_1^T + \cdots + u_r\sigma_rv_r^T$$

其中

- U 是一个 $n \times n$ 的矩阵，其列向量 u_i 叫做 A 的左奇异向量
- Σ 是一个 $n \times p$ 的矩阵，除了主对角线上的元素以外全为 0，主对角线上的每个元素 σ_i 都称为奇异值
- V 是一个 $p \times p$ 的矩阵，其列向量 v_i 叫做 A 的右奇异向量
- r 为矩阵 A 的秩(rank)
- U 和 V 都是正交矩阵，即满足: $U^T U = I_n, V^T V = I_p$

奇异值分解 (SVD)

U 矩阵求解

AA^T 为 $n \times n$ 的一个方阵，可以进行特征分解，其**特征值** λ_i 和**特征向量** u_i 满足：

$$(AA^T)u_i = \lambda_i u_i$$

可以得到矩阵 AA^T 的 n 个特征值和对应的 n 个特征向量。

- 将 AA^T 的所有特征向量组成一个 $n \times n$ 的矩阵 U ，即得SVD 公式中的 U 矩阵
- U 中的每个特征向量叫做 A 的左奇异向量。

注： $AA^T = (U\Sigma V^T)(U\Sigma V^T)^T = U(\Sigma\Sigma^T)U^T$

奇异值分解 (SVD)

V 矩阵求解

$A^T A$ 为 $p \times p$ 的一个方阵，可以进行特征分解，其**特征值** λ_i 和**特征向量** v 满足：

$$(A^T A)v_i = \lambda_i v_i$$

可以得到矩阵 $A^T A$ 的 p 个特征值和对应的 p 个特征向量。

- 将 $A^T A$ 的所有特征向量组成一个 $p \times p$ 的矩阵 V ，即得SVD 公式中的 V 矩阵
- V 中的每个特征向量叫做 A 的右奇异向量。

注： $A^T A = (U \Sigma V^T)^T (U \Sigma V^T) = V (\Sigma^T \Sigma) V^T$

奇异值分解 (SVD)

Σ 矩阵求解

可以看出特征值矩阵等于奇异值矩阵的平方，特征值和奇异值满足如下关系：

$$\sigma_i = \sqrt{\lambda_i}$$

这样也就是说，我们可以通过**求 $A^T A$ 特征值取平方根来求奇异值**。

我们也可以通过以下方式求左右奇异向量：

- $A = U\Sigma V^T$ ，则 $AV = U\Sigma V^T V = U\Sigma$

得到： $Av_i = \sigma_i u_i$ ， $u_i = Av_i / \sigma_i$

- $A^T = V\Sigma U^T$ ，则 $A^T U = V\Sigma U^T U = V\Sigma$

得到： $A^T u_i = \sigma_i v_i$ ， $v_i = A^T u_i / \sigma_i$

主成分分析 (PCA)

- **目标**：找到原始变量 $X = (X_1, \dots, X_p)$ 的**线性组合**，即**主成分** $(F_1, \dots, F_p)$

$$F_1 = a_{11}X_1 + \dots + a_{p1}X_p = \mathbf{a}_1^T X$$

⋮

$$F_p = a_{1p}X_1 + \dots + a_{pp}X_p = \mathbf{a}_p^T X$$

通常情况下，**取前 k 个主成分**即可。系数 (a_{ij}) 未知，需要求解。

- 我们自然希望 F_1 尽可能多地反映原来指标的信息，用方差 $D(F_1)$ 来表示信息，方差 $D(F_1)$ 越大，表明 F_1 所包含的信息越多。因而在所有的线性组合中，选取的 F_1 应该是方差最大的，作为**第一主成分**。依次类推，构造第2,3, ..., 第 p 个主成分，**主成分之间互不相关**，且其**方差是依次递减**的。

主成分分析 (PCA)

$$F_i = a_{1i}X_1 + \cdots + a_{pi}X_p = \mathbf{a}_i^T \mathbf{X}, \quad i = 1, \dots, p$$

- 系数 a_i 的约束

如果对系数没有限制，可能使得
 $D(F_i) = \mathbf{a}_i^T D(\mathbf{X}) \mathbf{a}_i$ 无穷大

1. $a_{1i}^2 + a_{2i}^2 + \cdots + a_{pi}^2 = 1, \quad i = 1, \dots, p$
2. F_i 与 F_j 不相关， $\text{Cov}(F_i, F_j) = 0 \quad (i \neq j, \quad i, j = 1, \dots, p)$
3. F_1 是 $X_1, \dots, X_p$ 的一切线性组合中方差最大的， F_2 是与 F_1 不相关的
 $X_1, \dots, X_p$ 一切线性组合中方差最大的， $\dots$ ， F_p 是与 $F_1, \dots, F_{p-1}$ 都不相
关的 $X_1, \dots, X_p$ 的一切线性组合中方差最大的。

主成分分析 (PCA)

- 样本矩阵 $\mathbf{X}$

$$\mathbf{X} = \begin{pmatrix} X_{(1)}^T \\ \vdots \\ X_{(n)}^T \end{pmatrix} = \begin{pmatrix} x_{11} & x_{12} & x_{1p} \\ x_{21} & x_{11} & x_{2p} \\ \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & x_{np} \end{pmatrix}$$

- 样本协方差矩阵 $\mathbf{S}$

$$\mathbf{S} = \frac{1}{n-1} \sum_{a=1}^n (X_{(a)} - \bar{X})(X_{(a)} - \bar{X})^T = (s_{ij})_{p \times p}$$

每个维度的均值

$$\bar{X} = \frac{1}{n} \sum_{a=1}^n X_{(a)} = (\bar{x}_1, \dots, \bar{x}_p)^T$$

$$s_{ij} = \frac{1}{n-1} \sum_{a=1}^n (x_{ai} - \bar{x}_i)(x_{aj} - \bar{x}_j)$$

s_{ii} 是第 i 个维度的方差

- 样本相关系数矩阵 $\mathbf{R} = (r_{ij})_{p \times p}$

$$r_{ij} = \frac{s_{ij}}{\sqrt{s_{ii}}\sqrt{s_{jj}}}$$

- 标准化后的样本矩阵 $\mathbf{Z} = (z_{ij})_{n \times p}$

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{\sqrt{s_{jj}}}$$

样本相关系数矩阵和标准化后的数据的样本协方差矩阵等价： $\mathbf{R} = \frac{1}{n-1} \mathbf{Z}^T \mathbf{Z}$

PCA实现步骤

假设有 n 条 p 维数据，将原始数据按列组成 n 行 p 列矩阵 $X_{n \times p}$ ，
第 i 行 j 列的元素 x_{ij} 表示第 i 个样本在第 j 个维度上的观测值

(1) 对原始数据进行标准化 (或中心化处理)

- 计算出每个特征的均值和方差： $\bar{x}_j, s_{jj}, j = 1, \dots, p$
- 样本观测值标准化： $z_{ij} = \frac{x_{ij} - \bar{x}_j}{\sqrt{s_{jj}}}$ ，构成标准化后的样本矩阵 $\mathbf{Z} = (z_{ij})_{n \times p}$
- 计算协方差矩阵： $\mathbf{R} = \frac{1}{n-1} \mathbf{Z}^T \mathbf{Z}$

PCA实现步骤

(2) 计算相关系数矩阵 R 的特征值和特征向量

- 对特征值从大到小排序： $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$ ，其对应的正交化后的特征向量分别表示为 $a_1, a_2, \dots, a_p$ ，其中 $a_i = (a_{1i}, a_{2i}, \dots, a_{pi})^T, i = 1, \dots, p$

(3) 计算方差前 k 个主成分的累积贡献率： $\alpha_k = \frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^p \lambda_i}$

- 根据累积贡献率阈值（一般达到85%以上）确定 k ，将前 k 个特征值对应的 k 个特征向量 $a_1, a_2, \dots, a_k$ 排列成特征向量矩阵 $P_{k \times p}$

(4) 写出主成分： $F_i = a_{1i}Z_1 + \dots + a_{pi}Z_p = a_i^T Z, i = 1, \dots, k$

(5) 将第 t 个样本 $Z_{(t)} = (Z_{t1}, \dots, Z_{tp})^T$ 的值代入 F_i 的表达式，计算出值称为第 t 个样本在第 i 个主成分的得分，记为 F_{ti} ：



$$F_{ti} = a_i^T Z_{(t)}, \quad i = 1, \dots, k, t = 1, \dots, n$$

MDS

- **目标**：假设原始空间为 p 维，给定 n 个样本的距离矩阵 $D = (d_{ij})$ ，要寻找 p 维空间中 n 个点 $(X_{(1)}, \dots, X_{(n)}) \in R^p$ ，其中 $X_{(i)} = (x_{i1}, \dots, x_{ip})$ ，使得

$$d_{ij} \approx \|X_{(i)} - X_{(j)}\|_2$$

- MDS只要求距离矩阵 D 给定
- 当 d_{ij} 为欧式距离时，可以取到等号；当 d_{ij} 为非欧式距离（如弧度距离，Radian distance）时，等号不能取到。



Point	a	b	c	d
a	0.0000	3.1416	0.7854	1.5708
b	3.1416	0.0000	2.3562	1.5708
c	0.7854	2.3562	0.0000	2.3562
d	1.5708	1.5708	2.3562	0.0000

MDS

- MDS的解不唯一：

$$\|X_{(i)}^* - X_{(j)}^*\|_2 = \|(X_{(i)} + c) - (X_{(j)} + c)\|_2 = \|X_{(i)} - X_{(j)}\|_2$$

- 前提条件：MDS中假定要寻找的 p 维空间中 n 个点 $(X_{(1)}, \dots, X_{(n)})$ 在每个维度上都是中心化的：

$$\sum_{i=1}^n x_{ik} = 0, \forall k = 1, \dots, p.$$

MDS

- 记 $X = (X_{(1)}^T, \dots, X_{(n)}^T)^T$, 令 Gram matrix $B_{n \times n} = XX^T = (b_{ij})$, 则

$$d_{ij}^2 = b_{ii} + b_{jj} - 2b_{ij}$$

$$\|X_{(i)} - X_{(j)}\|_2^2 = X_{(i)}^T X_{(i)} + X_{(j)}^T X_{(j)} - 2X_{(i)}^T X_{(j)}$$

由此我们可以得到

$$\sum_{i=1}^n b_{ij} = \sum_{i=1}^n \sum_{k=1}^p x_{ik} x_{jk} = \sum_{k=1}^p x_{jk} \sum_{i=1}^n x_{ik} = 0$$

记 $T = \text{trace}(B) = \sum_{i=1}^n b_{ii}$, 则有

$$n d_{.j}^2 = \sum_{i=1}^n d_{ij}^2 = T + n b_{jj}, n d_{i.}^2 = \sum_{j=1}^n d_{ij}^2 = T + n b_{ii}, n^2 d_{..}^2 = \sum_{i=1}^n \sum_{j=1}^n d_{ij}^2 = 2nT$$

$$b_{ij} = -\frac{1}{2}(d_{ij}^2 - d_{.j}^2 - d_{i.}^2 + d_{..}^2)$$

假设 B 的谱分解为 $B = V \Sigma V^T$, 则

$$X = V \Sigma^{1/2}$$

MDS

- 假设 B 的特征值分解为 $B = V\Sigma V^T$, 则

$$\mathbf{X} = V\Sigma^{1/2}$$

- 若要实现降维, 即降维后的维度 $d < p$, 则降维后的数据矩阵为

$$P_{(d)} = V_d \Sigma_d^{1/2}$$

其中 V_d 为 V 的前 d 列, $\Sigma_d^{1/2}$ 为 $\Sigma^{1/2}$ 的前 $d \times d$ 的子矩阵。

聚类分析

- 不同距离的定义
- 不同距离的优点和缺点
 - 样本点之间按什么刻画相似程度?
 - 样本点和小类之间按什么刻画相似程度? 
 - 小类与小类之间按什么来刻画相似程度?
- Kmeans聚类的原理

回归分析

- 多元线性回归的模型假设: Gauss-Markov假设
- 最小二乘估计的思路
- 最小二乘估计的性质
- 最小二乘估计和极大似然估计的关系

关联分析



- 支持度和置信度的定义和计算
- 频繁项集的定义
- 强关联规则
- Apriori算法思想与实现步骤
- Apriori算法与FP增长算法的区别

关联分析

关联规则

- 集合 $I = \{i_1, i_2, \dots, i_m\}$ 为标识符的集合，其中 m 为正整数， $i_k (k = 1, \dots, m)$ 称为项目 (item)。
- 项目是一个从具体问题中抽象出的一个概念。在超市的关联规则挖掘问题中，项目表示各种商品，如旅游鞋等。由于在超市的关联规则挖掘中并不关心顾客购买的商品数量和价格等，因此顾客的一次购物可以用该顾客所购买的所有商品的名称来表示，称为事务 (transaction)，所有事务的集合构成关联规则挖掘的数据集，称为事务数据库。

关联分析

事务

- 关联规则挖掘的数据库记为 D ，事务数据库 D 中的每个元组称为事务，一条事务 T 是 I 中项目的集合。一条事务仅包含其涉及到的项目，而不包含项目的具体信息。在超级市场的关联规则挖掘问题中事务是顾客一次购物所购买的商品，但事务中并不包含这些商品的具体信息，如商品的数量、价格等。

事务数据集的矩阵表示

事务	项目	i_1	i_2	i_3	i_4	i_5	i_6
10		1	1	1	0	0	0
20		1	0	1	0	0	0
30		1	0	0	1	0	0
40		0	1	0	0	1	1

事务数据集

事务	购买商品（项集）
10	i_1, i_2, i_3
20	i_1, i_3
30	i_1, i_4
40	i_2, i_5, i_6

关联分析

项目集

- 项目集是由 I 中项目构成的集合。若项目集包含的项目数为 k ，则称此项目集为 k -项目集。任意的项目集 X 和事务 T 若满足 $X \subset T$ ，则称事务 T 包含项目集 X 。在超市的关联规则挖掘问题中项目集可以看成一個或多个商品的集合。若某顾客一次购买所对应的事务 T 包含项目集 X ，就说该顾客在这次购物中购买了项目集 X 中的所有商品。
- **频繁项目集**: 对任意的项目集 X ，若事务数据库 D 中占比为 $\epsilon\%$ 的事务包含项目集 X ，则项目集的支持率为 $\epsilon\%$ ，记为 $\text{support}(X) = \epsilon\%$ ，其中包含项目集 X 的事务数称为项目集 X 的频度，记为 $\text{support_count}(X)$ 。若项目集 X 的支持率大于或等于用户指定的最小支持率（ min_support ），则项目集 X 称为**频繁项目集**（或大项目集），否则项目集 X 为非频繁项目集（或小项目集）。如果数据库 D 中的事务数记为 $|D|$ ，频繁项目集是至少被 $\epsilon\%|D|$ 条事务包含的项目集。

关联分析

支持度和置信度

- 关联规则是形如 $U \rightarrow V$ 的规则，其中 U, V 为项目集且 $U \cap V = \emptyset$ 。在数据库 D 中，若 $s\%$ 的事务包含 $U \cup V$ ，则关联规则 $U \rightarrow V$ 的支持度为 $s\%$ ；在数据库 D 中，若 $c\%$ 的包含项目集 U 的事务也包含项目集 V ，则关联规则 $U \rightarrow V$ 的置信度为 $c\%$ ：

在事务数据库 D 中，关联规则 $U \rightarrow V$ 的支持度为：

$$s(U \rightarrow V) = \frac{\text{support_count}(U \cup V)}{|D|}$$

关联规则 $U \rightarrow V$ 的置信度为：

$$c(U \rightarrow V) = \frac{\text{support_count}(U \cup V)}{\text{support_count}(U)}$$

式中， $\text{support_count}(U \cup V)$ 是包含项集 $U \cup V$ 的事务数， $\text{support_count}(U)$ 是包含项集 U 的事务数。

关联规则

支持度和置信度

- 若关联规则 $U \rightarrow V$ 的支持度和置信度分别大于或等于用户指定的最小支持率 min_support 和最小置信度 min_confidence ，则称关联规则 $U \rightarrow V$ 为**强关联规则**，否则称关联规则 $U \rightarrow V$ 为弱关联规则。
- 关联规则挖掘的核心就是要找出事务数据库 D 中的所有强相关规则。

关联规则性质

- 性质1：频繁项集的子集必为频繁项集。
- 性质2：一个 k -项集，如果它的一个 $k - 1$ 项集（它的子集）不是频繁的，那它本身也不可能是频繁的。

KNN & 朴素贝叶斯

- KNN原理
- 朴素贝叶斯原理

感知机和SVM

- 模型原理：
 - 模型数学表达式
 - 模型的损失函数
- 模型的算法流程

决策树与集成学习

- 掌握信息论原理：熵、条件熵、互信息的定义及联系
- 熟悉不同决策树算法