

回归分析 第二次上机作业 2112054 王赫明

研究用电高峰时居民家庭每小时的用电量Y与每月总用电量X之间的关系。

53户居民某月用电记录见“3-15.xlsx”，试完成以下统计分析：

```
In [12]: A<-read.csv("hw2.csv")
head(A)
```

A data.frame: 6 × 3

	Users	X	Y
	<int>	<int>	<dbl>
1	1	679	0.79
2	2	292	0.44
3	3	1012	0.56
4	4	493	0.79
5	5	582	2.70
6	6	1156	3.64

(1) 应用最小二乘法求经验回归方程;

```
In [14]: lm.reg<-lm(Y~X, data=A)
summary(lm.reg)
```

Call:

```
lm(formula = Y ~ X, data = A)
```

Residuals:

Min	1Q	Median	3Q	Max
-4.0911	-0.8147	-0.1965	1.2446	3.2006

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.7880079	0.4499583	-1.751	0.0859 .
X	0.0036186	0.0003376	10.719	1.15e-14 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.609 on 51 degrees of freedom


Multiple R-squared: 0.6926, Adjusted R-squared: 0.6866

F-statistic: 114.9 on 1 and 51 DF, p-value: 1.146e-14

利用R中的lm.reg函数直接求解，得到经验回归方程为: $\hat{y} = 0.0036186x - 0.7880079$


(2) 以拟合值 $\hat{y}_i$ 为横坐标，学生化残差 r_i 为纵坐标，作残差图，分析Gauss-Markov假设对本例的适用性；

```
In [15]: y.stu<-rstudent(lm.reg)
y.fit<-predict(lm.reg)
plot(y.stu~y.fit)
```



可以看到，残差分析图中，散点并不是完全的随机分布在横轴两侧，而是具有一定的呈“漏斗”状的趋势，因此不能认为该模型是方差齐性的，即本数据集对于Gauss_Markov的适配性能较差。

```
In [16]: par(mfrow=c(2,2))
plot(lm.reg)
```



(3) 考虑因变量的变换 $U = Y^{\frac{1}{2}}$ ，再对新变量U和X重复(1)和(2)的统计分析:

```
In [20]: #求解最小二乘线性回归
lm.trans<-update(lm.reg, sqrt(. )~.)
summary(lm.trans)
```

Call:

```
lm(formula = sqrt(Y) ~ X, data = A)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-1.38013	-0.31045	-0.02535	0.26631	0.82191

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	5.896e-01	1.310e-01	4.502	3.94e-05 ***
X	9.396e-04	9.826e-05	9.562	5.81e-13 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 0.4683 on 51 degrees of freedom

Multiple R-squared: 0.6419, Adjusted R-squared: 0.6349

F-statistic: 91.43 on 1 and 51 DF, p-value: 5.811e-13

变换后的经验回归方程为: $\hat{u} = 0.0009396x + 0.5896$


```
In [21]: par(mfrow=c(1,1))
y.stu<-rstudent(lm.trans)
y.fit<-predict(lm.trans)
plot(y.stu~y.fit)
```



可以看出，变换后的学生化残差图中，散点没有明显的形状分布，更接近于随机分布在横轴两侧。

说明变换有效解决了方差齐性问题，提高了Gauss-Markov Hypo.的适用性！


```
In [23]: par(mfrow=c(2,2))  
plot(lm.trans)
```



对比变换前的各图像，曲线的平稳程度均有一定提升。

(4) 将Box-Cox变换应用到本例，计算变换参数入的值，并做讨论；

```
In [36]: library(MASS)
par(mfrow=c(1,1))
result <- boxcox(lm.reg, lambda = seq(-1, 1, length = 50))
```



```
In [38]: #寻找最优lambda值
result$x[which.max(result$y)]
```

0.535353535353535

从图像中，可以看到 λ 在0.5略偏右处为最优值，输出结果显示该最优值为0.53。


在上一问的开方变换中，已经可以从图像中看出残差在横轴附近波动，方差齐性较好。因此，为了计算简便，也可以直接取 $\lambda = 0.5$ 。

(5) 作影响分析，找出强影响点。

一般认为Cook距离 $D > \frac{4}{n-k-1}$ 时，为强影响点， n 为数据个数， k 为预测变量数，取 $n=53, k=1$:

```
In [46]: #绘制Cook's Distance与lambda的关系图，找出最优lambda值
cook<-cooks.distance(lm.reg)
cutoff <- 4/51
plot(lm.reg, which = 4, cook.levels = cutoff)
abline(h=cutoff, lty=2, col="blue")
cook[cook>4/51]
```


8: 0.0809891181427714 **50:** 0.803778563405779 **52:** 0.175637856938474



因此，第8，50，52条数据是强影响点，应该剔除。

```
In [57]: #剔除强影响点
A_delete<-A[-52, ]
A_delete<-A_delete[-50, ]
A_delete<-A_delete[-8, ]

#绘制学生化残差图
lm.reg<-lm(Y~X, data=A_delete)
y.stu<-rstudent(lm.reg)
y.fit<-predict(lm.reg)
plot(y.stu~y.fit)
```



剔除了三个强影响点，学生化残差图有所改善，但仍可看出其“漏斗状”的分布趋势。