

机器学习期末复习

南开大学统计与数据科学学院，马东升

2024 年 12 月 22 日

前言：两位老师的完全交集如下：

- 决策树
- 朴素贝叶斯
- knn
- k-means
- 感知机
- 人工神经网络
- 垂直平分分类器
- SVM

而以下是两位老师讲的主题相同，但内容有所不同的：

- 图像处理基础算法（付老师讲了颜色、纹理、边缘、形状，潘老师讲的较少）
- 判别分析（付老师讲的较多，潘老师未讲多总体的判别分析）
- 优化算法、数据（类型、可视化、编码）、重抽样（Bootstrap）、模型评价等内容。两个老师都讲了，但内容相差较大，且主要是描述性的，故未收录。待后续补充。

此外：

- 文本基础算法及距离和相似度（付老师独占，本文未收录，待后续补充）
- 降维方法（潘老师独占，本文未收录）

目录

1	决策树	4
1.1	决策树简介和内容总结	4
1.2	回归树	4
1.3	分类树	5
2	朴素贝叶斯	8
2.1	背景与来源	8
2.2	关键假设	8
2.3	计算实例	8
2.4	算法问题及解决方案	9
3	KNN	10
3.1	KNN 分类	10
3.2	KNN 回归	10
3.3	优点与缺点	11
4	K-means 聚类算法	12
4.1	K-means 聚类算法流程	12
4.2	算例	12
4.3	K 的确定	12
4.4	K-means 的缺点	13
5	感知机	14
5.1	算法流程	14
5.2	算法实例	14
5.3	Delta 规则下的算法流程	14
6	人工神经网络	16
6.1	激活函数	16
6.2	前馈神经网络 (FNN)	17
6.3	反向传播算法 (BP 算法)	18
6.4	神经网络的正则化	20
6.5	实例	21
7	垂直平分分类器	22
7.1	决策边界和分类规则	22
7.2	实例	22
7.3	特点	22
8	SVM 支持向量机	23
8.1	超平面	23
8.2	最大间隔分类器	23
8.3	支持向量分类器	25
8.4	核函数	26

9 图像特征提取	28
9.1 图像基本概念	28
9.2 图像特征基本概念	28
9.3 颜色特征提取	28
9.4 纹理特征提取	29
9.5 边缘特征提取	31
9.6 形状特征提取	32
10 判别分析	34
10.1 两个总体的贝叶斯判别方法	34
10.2 两个多元正态分布（同方差）的线性判别方法 LDA	34
10.3 两个同方差总体的 Fisher 判别方法（Fisher LDA）	35
10.4 两个多元正态分布（异方差）的二次判别方法（QDA）	35
10.5 先验概率未知时，到底如何估计	36
10.6 分类效果的评价——TPM	36
10.7 多个总体的贝叶斯判别方法	36
10.8 多个多元正态分布（异方差）的二次判别方法 QDA	37
10.9 多个多元正态分布（同方差）的线性判别方法 LDA	37
10.10 多个总体（同方差）的 Fisher 判别方法（Fisher LDA）	38

1 决策树

1.1 决策树简介和内容总结

1. 建立决策树的准则和方法
2. 决策树如何判断和预测
3. 决策树如何避免欠拟合和过拟合

决策树可以分为：回归树和分类树。

决策树的基本原理是：寻找特征空间的最佳分裂点或切分点，将复杂的决策问题分割成一系列简单的子问题，以达到最有预测的方法。

1.2 回归树

回归树的主要目的：自动选择最优的分类变量 X_j 和分裂点 t ，并建立回归树模型。步骤如下

1. 将 $X_1, \dots, X_p$ 的特征空间分割成 K 个互不重叠的区域 $R_1, \dots, R_K$
2. 对落入 R_k 的每个观测值做预测，预测值等于 R_k 内训练集的响应变量值的平均值。

1.2.1 递归二叉分类法

自上而下，将协变量空间划分为超矩形，找到使回归树模型的 $RSS = \sum_{k=1}^K \sum_{i: \mathbf{x}_i \in R_k(j,t)} (y_i - \bar{y}_{R_k})^2$ 最小的超矩形区域 $R_1, \dots, R_K$ 。步骤如下

1. 对于分类变量 X_j 和分裂点 t ，将特征空间分为互不重叠的两个区域： $R_1(j, t) = \{\mathbf{X} | X_j < t\}$, $R_2(j, t) = \{\mathbf{X} | X_j \geq t\}$ 。
2. 遍历所有协变量 $X_1, \dots, X_p$ 和每个协变量对应 t 的所有取值，选择使 RSS 最小的 j 和 t

$$RSS = \sum_{i: \mathbf{x}_i \in R_1(j,t)} (y_i - \bar{y}_{R_1})^2 + \sum_{i: \mathbf{x}_i \in R_2(j,t)} (y_i - \bar{y}_{R_2})^2$$

3. 重复 1, 2 两步，直到终止准则。

可以看出，递归二叉分类法最终使得训练集上 RSS 最小（对于固定的 K ，即划分次数固定）。

- 如果树较深，很可能会过拟合，导致在测试集上预测效果变差（偏差小但方差大）
- 如果叶节点或终端较少，方差小，但是偏差大，可能会欠拟合。

1.2.2 代价复杂度减枝

策略：先生成一个很大的回归树 T_0 ，然后通过代价复杂度减枝，选出使得测试预测误差最小的子树。考虑惩罚 RSS：

$$RSS' = \sum_{k=1}^{|T|} \sum_{i: \mathbf{x}_i \in R_k(j,t)} (y_i - \bar{y}_{R_k})^2 + \lambda |T|$$

其中 $|T|$ 表示树 T 的叶节点数（划分的区域）。

调节参数 λ ： $\lambda = 0$ ，子树相当于原树 T_0 ；随着 λ 增大，得到对应的一系列子树。

λ 的选取，使用 k 折交叉验证方法：

1. 生成一个很大的回归树 T_0 (终止准则可以是某个超矩形中包含的样本数低于某个最小值)
2. 对 T_0 进行代价复杂度减枝, 即通过输入不同的 λ , 得到不同的子树 T 。
3. 将训练集分为 k 折, 对每一折 $j(j = 1, \dots, k)$, 有:
 - (a) 对不属于 j 折的训练集, 重复步骤 1 和 2, 得到与 λ 一一对应的子树
 - (b) 计算子树在第 j 折上的预测均方误差
 - (c) 每个 λ 有 k 个预测均方误差, 将这 k 个均方误差求平均, 选出最优的 λ
4. 确定最优的 λ 后, 在步骤 2 中给出最优 λ 对应的子树 T 。

1.3 分类树

目的: 用于预测定性变量。预测时, 选择观测值所属区域内的训练集中最常出现的类。

方法: 递归二叉分裂法; 但要更换准则 (不能使用 RSS), 准则有:

1. 分类错误率 (不够敏感)
2. 信息增益
3. 基尼指数

1.3.1 分类错误率

$$errRate_k = 1 - \max_j (\hat{p}_{kj})$$

$errRate_k$ 表示 R_k 的分类错误率, $\max_j (\hat{p}_{kj})$ 表示 R_k 中最常见的类所占 R_k 中总训练样本的比例。
二分类问题, $errRate_k$ 是特别的:

$$errRate_k = 1 - \max(\hat{p}_{k1}, 1 - \hat{p}_{k1}) = \begin{cases} 1 - \hat{p}_{k1} & 0.5 \leq \hat{p}_{k1} \leq 1 \\ \hat{p}_{k1} & 0 \leq \hat{p}_{k1} \leq 0.5 \end{cases}$$

但这一准则不够敏感, 所以后续被弃用。

1.3.2 信息增益 (信息熵)

信息熵: 假设 X 是取有限值的离散型随机变量, 概率分布为 $P(X_i = x_i) = p_i (i = 1, \dots, n)$, 则 X 的信息熵定义为:

$$H(X) = - \sum_{i=1}^n p_i \log p_i$$

补充: 以 2 为底, 单位为比特或香农; 以 e 为底, 单位为奈特。可以把信息熵记为 $H(p) = - \sum_{i=1}^n p_i \log p_i$, 这是因为信息熵只与分布有关, 与取值无关。

$$0 \leq H(p) \leq \log n$$

证明略, 但是取等条件容易看出, 右侧取等即 $p_i = 1/n$ 。

对随机变量 (X, Y) , 假设联合密度为 $P(X = x_i, Y = y_j) = p_{ij}$, $P(X = x_i) = p_i$, 则条件熵 $H(Y|X)$ 为:

$$H(Y|X) = \sum_{i=1}^n p_i H(Y|X = x_i)$$

用极大似然估计（即用样本个数去估计 p_i 等）时，信息熵和条件熵分别被称作**经验信息熵**和**经验条件熵**。

如经验信息熵为： $H(D) = -\sum_{j=1}^J \frac{|C_j|}{|D|} \log_2 \frac{|C_j|}{|D|}$ ， $|C_j|$ 表示属于目标变量第 j 类的样本个数。

信息增益 $g(D, X)$ 被定义为：

$$g(D, X) = H(D) - H(D|X)$$

其中 $H(D)$ 和 $H(D|X)$ 分别是训练集上的**经验信息熵**和**经验条件熵**。

信息增益算法步骤如下：

1. 计算训练集的经验信息熵 $H(D)$
2. 对于特征变量 X ，计算经验条件熵 $H(D|X)$
3. 算出信息增益 $g(D, X) = H(D) - H(D|X)$ ，选择最大的使得信息增益最大的 X 作为分裂节点
4. 对划分后的子集，重复以上步骤

实例，非常简单的一个例子，试使用信息增益算法构建出决策树。

表 1: 信息增益手动计算决策树		
天气	温度	是否踢球（目标变量）
Sunny	High	No
Sunny	Low	Yes
Cloudy	High	Yes
Cloudy	Low	Yes
Rainy	High	No
Rainy	Low	No

1.3.3 信息增益比

信息增益的问题：会偏向于选择取值较多的特征变量。

信息增益比可以作为对该问题校正的一个准则。

$$g_R(D, X) = \frac{g(D, X)}{H_X(D)}$$


$H_X(D)$ 是集合 D 关于 X 的经验熵（即把 X 看作目标变量计算经验熵）。

1.3.4 基尼系数

在分类问题中，假设有 J 个类，样本点属于第 j 个类的概率为 p_j ，则基尼系数定义为：

$$Gini(p) = 1 - \sum_{j=1}^J p_j^2$$

下图显示了二分类问题中三者的关系。



二分类问题中基尼指数, 信息熵(除以2, 单位: 比特)和分类错误率的关系

图 1: 基尼系数, 信息熵, 分类错误率的关系

用基尼系数的原因: 计算速度快, 无需对数运算。

对给定的样本数据集 D , 仍然用极大似然估计, 其基尼系数为 ($|C_j|$ 表示属于目标变量第 j 类的样本个数):

$$Gini(D) = 1 - \sum_{j=1}^J \left(\frac{|C_j|}{|D|} \right)^2$$

假设 D 可以被某个特征变量 X 的某个值 x 划分为 D_1 和 D_2 , 那么此时基尼系数可以定义为:

$$Gini(D, X) = \frac{|D_1|}{|D|} Gini(D_1) + \frac{|D_2|}{|D|} Gini(D_2)$$

选择准则: 使得 $Gini(D) - Gini(D, X)$ 最大 (这称为 “结点不纯度下降最多” 或 “基尼系数值变化最大”) 的特征变量和分裂点作为分裂节点。

补充: 可以用基尼系数算之前的例子, 比较一下。

1.3.5 代价复杂度减枝

分类树也可以做代价复杂度剪枝:

$$C_\lambda(T) = C(T) + \lambda|T|$$

其中 $C(T)$ 是预测误差或损失函数 (基尼系数、信息熵等)。 λ 越大, 模型越简单, 偏差大而方差小。也可以通过 k 折交叉验证找到最优 λ 。

2 朴素贝叶斯

2.1 背景与来源

如果我们考虑 0-1 损失函数, $L(\hat{C}, C) = I\{\hat{C} \neq C\}$, 分类任务目标定为最小化损失函数的期望。

假设选择 $\hat{C}$, $E[L] = \sum_{k=1}^K P(C_k|X)L(\hat{C}, C_k) = 1 - P(\hat{C}|X)$ 。则最小化期望等价于最大化 $P(\hat{C}|X)$, 所以后续考虑用贝叶斯公式考虑 $P(\hat{C}|X)$ 。

2.2 关键假设

核心公式即为贝叶斯公式:

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

公式中起核心作用的是分子项, 所以我们计算时只考虑分子 (分母与分类无关)。

朴素贝叶斯是典型的生成学习方法: 先学习 $P(X, Y) = P(X|Y)P(Y)$, 再求得 $P(Y|X)$ 。

先看 $P(Y)$ 的估计:

$$P(Y = c_k) = \frac{\#\{Y = c_k, Data = Train\}}{\#\{Data = Train\}} \quad (1)$$

再看 $P(X|Y)$, 这里要用到关键假设, 即条件独立性假设:

$$P(X = x|Y = c_k) = P(X^{(1)} = x^{(1)}, \dots, X^{(n)} = x^{(n)}|Y = c_k) = \prod_{j=1}^n P(X^{(j)} = x^{(j)}|Y = c_k)$$

其中 $P(X^{(j)} = x^{(j)}|Y = c_k)$ 用下式估计:

$$P(X^{(j)} = x^{(j)}|Y = c_k) = \frac{\#\{X^{(j)} = x^{(j)}, Y = c_k, Data = Train\}}{\#\{Y = c_k, Data = Train\}} \quad (2)$$

这样, 我们就可以计算得出 $P(X = x|Y = c_k)P(Y = c_k) (k = 1, \dots, K)$, 选择其中最大的一个作为我们的类别估计。

2.3 计算实例

下面是一个很简单的计算实例, 新员工的特征是: Education = Graduate, Experience = 0-5 years, Skill = Medium; 用朴素贝叶斯方法计算其是否会被晋升。

表 2: 朴素贝叶斯计算实例

Education	Experience	Skill	Promotion (目标变量)
Graduate	5+ years	High	Yes
Undergraduate	5+ years	High	No
Graduate	0-5 years	Medium	Yes
Undergraduate	0-5 years	Low	No
Graduate	5+ years	Medium	Yes
Graduate	0-5 years	High	Yes
Undergraduate	5+ years	Low	No
Graduate	0-5 years	Medium	No
Undergraduate	0-5 years	Medium	No
Graduate	5+ years	Medium	Yes

2.4 算法问题及解决方案

问题 1：连续变量如何处理？

- 离散化：即手动将变量范围划分为不同的区间，如将 $x \geq 0$ 这一协变量划分为 $[0, 100]$ 和 $[100, \infty]$ 这两个区间。
- 假设分布法：假设连续性变量的分布（如正态分布），先用训练集去估计参数，得到估计的概率密度函数。之后使用概率密度函数作为连续变量的概率估计。

问题 2：没有这一类型怎么办？（(1)(2) 式的分子为 0）

用平滑参数 λ ，如对 (2) 式：

$$P_{\lambda}(X^{(j)} = x^{(j)} | Y = c_k) = \frac{\#\{X^{(j)} = x^{(j)}, Y = c_k, Data = Train\} + \lambda}{\#\{Y = c_k, Data = Train\} + S_j \lambda} \quad (3)$$

其中 S_j 为 $X^{(j)}$ 的类型总数。 λ 通常可以取 1。

3 KNN

K 近邻是一种有监督的机器学习算法，主要通过对距离的度量及选择合适的 K 值对数据作分类和回归。

3.1 KNN 分类

3.1.1 两种范式

与朴素贝叶斯学习 $P(X, Y)$ 不同，KNN 算法实际上是直接学习 $P(Y|X)$ ，这种方法被称为判别学习方法。

这一好处是无需估计先验概率和协变量 X 的分布情况（朴素贝叶斯实际上是将两个估计量相乘）。

3.1.2 算法流程

1. 给定训练集 D 和正整数 K ，计算 D 中每个样本点的特征向量 $\mathbf{x}_i$ 到所需预测的特征向量 $\mathbf{x}_0$ 的距离（距离有各种不同的定义）。在 D 中找出与 $\mathbf{x}_0$ 最近的 K 个样本点，将这 K 个样本点的集合记作 N_0 。
2. 直接计算条件概率 $P(Y = j | \mathbf{X} = \mathbf{x}_0)$ 的估计值 $\hat{p}_j = \frac{1}{K} \sum_{\mathbf{x}_i \in N_0} I(y_i = j)$
3. 将 $\mathbf{x}_0$ 分到概率最大的类中，如 $\hat{p}_j$ 最大，则将 $\mathbf{x}_0$ 分到第 j 类。

注：第二步可以直接计算 $\sum_{\mathbf{x}_i \in N_0} I(y_i = j)$ ，然后通过多数票规则进行分类。

3.1.3 K 值选择

$K=1$ ，最近邻算法，偏差小但方差很大，过拟合； K 很大时，方差小（ K 取全样本方差为 0），偏差很大，欠拟合。

所以需要平衡方差和偏差，使用数据驱动的交叉验证方法。

3.1.4 实例

现在给出一个新的数据点 $(x_1, x_2) = (4, 4)$ ，请使用不同 k 值，基于表 3，对样本进行分类（距离采用欧氏距离）。

表 3: KNN 计算实例			
样本编号	x_1	x_2	标签
1	1	2	A
2	2	3	A
3	3	3	B
4	6	5	B
5	7	8	B

3.2 KNN 回归

3.2.1 算法流程

1. 给定训练集 D 和正整数 K ，计算 D 中每个样本点的特征向量 $\mathbf{x}_i$ 到所需预测的特征向量 $\mathbf{x}_0$ 的距离（距离有各种不同的定义）。在 D 中找出与 $\mathbf{x}_0$ 最近的 K 个样本点，将这 K 个样本点的集合记作 N_0 。

2. 直接在 N_0 中使用平均值来估计回归函数，即

$$\hat{g}(\mathbf{x}) = \frac{1}{K} \sum_{\mathbf{x}_i \in N_0} y_i$$

3.2.2 误差分析

假设测试样本 $(\mathbf{x}_0, y_0)$ 满足 $y_0 = g(\mathbf{x}_0) + \varepsilon_0$ ，可以计算得出期望测试均方误差 (MSE) 为：

$$E(y_0 - \hat{g}(\mathbf{x}_0))^2 = \sigma^2 + [g(\mathbf{x}_0) - \frac{1}{K} \sum_{i=1}^K y_i]^2 + \frac{\sigma^2}{K}$$

可以看出， K 很小时，偏差（第二项）很小但方差（第三项）很大； K 很大时，偏差很大但方差很小。

3.3 优点与缺点

3.3.1 优点

- 实现简单
- 无需对模型进行假设（model-free）
- 稳健性强，对异常值不敏感
- 预测效果好，在训练样本足够大的条件下

3.3.2 缺点

- K 值影响太大，选定标准和过程比较复杂
- 计算成本高
- 维数灾难：高维的 $\mathbf{X}$ 难以收敛和预测

4 K-means 聚类算法

聚类分析，是在一个数据集中寻找子群或类的无监督的统计学习方法。

所谓类，通俗来说就是相似元素的集合。

聚类分析是按照观测样本取值的相似程度，对观测样本进行分类，使得同一类内的观测样本是相似的，不同类间的观测样本是不相似的。

4.1 K-means 聚类算法流程

将样本集合划分为 K 个类，将 n 个观测样本分到 K 个类中，要求每个观测样本只能属于一个类，且每个观测样本到其所属类中心的距离最小。

其核心思想是：使同类内所有数据点的总体差异性尽可能小。

理论上来说，我们应该需要最小化下面的目标函数：

$$\sum_{k=1}^K W(G_k) = \sum_{k=1}^K \frac{1}{|G_k|} \sum_{i,i' \in G_k} \sum_{j=1}^p (x_{ij} - x_{i'j})^2$$

但求解这一最优化问题需要 K^n 的复杂度，当样本较大时，这几乎是不可能的。

所以我们有了局部最优的 K 均值聚类算法：

1. 为每个观测样本随机分配一个从 1 到 K 的数字，可以看作是观测样本的初始类。
2. 重复以下操作，直到类不再改变：
 - (a) 分别计算 K 个类的中心，中心即为类中样本的均值向量
 - (b) 将每个观测样本分配到距离其最近的类中心所在的类中

第 1 步也可以改为，随机选取 K 个样本点作为聚类中心。

4.2 算例

指定初始的聚类中心为 $C_1 = (1, 1), C_2 = (5, 7)$, $K = 2$ ，请用 K-means 算法将下列 5 个样本点聚类。

表 4: K-means 算例

x_1	x_2
1	1
1.5	2
3	4
5	7
3.5	5

4.3 K 的确定

K-means 聚类方法的一个缺点：需要实现确定一个 K 。

4.3.1 肘方法

为了确定这个 K ，我们先定义类内总平方和：

$$WSS_K = \sum_{l=1}^K SS^{(l)} = \sum_{l=1}^K \sum_{i=1}^{n_l} \sum_{j=1}^p (x_{ij}^{(l)} - \bar{x}_j^{(l)})^2$$

- 如果 K 增加, 那么 WSS_K 会逐渐减少
- 当 K 增加到样本容量 n 时, $WSS_K = 0$

肘方法指的是: 逐渐增加 K , 观察 WSS_K 的减少趋势。减少到一定量时, WSS_K 减少变慢, 这时就停止增加 K 。




图 2: 肘方法示意图

4.3.2 信息准则方法

$$\hat{K} = \arg \min_K \{WSS_K + \lambda pK\}$$

- $\lambda \geq 0$ 是调节参数, 取不同值就是不同的信息准则; 如 $\lambda = 2$, 对应 AIC 准则; 如 $\lambda = \log(n)$, 对应 BIC 准则

4.4 K-means 的缺点

- 需要事先确定 K
- 对于椭球或椭圆形状区域的聚类比较适用, 对非凸数据集聚类可能失效
- 对异常值敏感, 需要作异常值处理

5 感知机

感知机是二分类的线性分类模型，输入为 $\mathbf{x}$ ，输出为 +1 或 -1。属于判别模型，目标是要将输入实例通过分离超平面将正负例分离。

使用梯度下降法对损失函数进行极小化。损失函数如下

$$L(w, b) = - \sum_{\mathbf{x}_i \in M} y_i (\mathbf{w}^T \mathbf{x}_i + b)$$

5.1 算法流程

输入: $T = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$, 学习率 η ; 输出: $\mathbf{w}, b$ 。

步骤流程:

1. 初始化 $\mathbf{w}_0, b_0$ (随机或取 0)
2. 在数据集中选取数据 $(\mathbf{x}_i, y_i) (i = 1, 2, \dots, N)$
3. 设 $o_i = I(\mathbf{w}\mathbf{x}_i + b > 0)$, 更新参数:

$$\begin{aligned}\mathbf{w} &\leftarrow \mathbf{w} + \eta \frac{(y_i - o_i)}{2} \mathbf{x}_i \\ b &\leftarrow b + \eta \frac{(y_i - o_i)}{2} y_i\end{aligned}$$

4. 转到 (2), 直到训练集中没有误分类点。

如何理解 $(y_i - o_i)$? 事实上, 如果该样本点预测正确, $y_i - o_i = 0$, 也就是不更新参数; 即对所有误分类点做参数更新。

这样写法主要是为了与后面基于 delta 方法的感知机对应。

5.2 算法实例

请根据下述样本点和初值 $\mathbf{w}_0 = (0, 1), b_0 = 0$, 更新感知机, $\eta = 1$, 直到没有误分类点。

表 5: 感知机训练实例

x_1	x_2	y
-1	-1	1
-1	1	1
1	1	-1
1	-1	-1

5.3 Delta 规则下的算法流程

感知机的问题: 样例线性可分时, 可以找到一个权向量; 但如果不是线性可分, 则不能收敛。

delta 准则会对非线性可分的样本收敛到最佳近似, 其核心思想是通过梯度下降法调整权重, 以最小化输出与目标值直接的误差, 通常是均方误差。即损失函数改为下述:

$$L(w, b) = -\frac{1}{n} \sum_{\mathbf{x}_i \in M} \frac{1}{2} (y_i - g(\mathbf{w}^T \mathbf{x}_i + b))^2$$

其中 g 是激活函数, 在二分类问题中常使用 sigmoid 函数。算法流程如下:

输入: $T = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$, 学习率 η ; 输出: $\mathbf{w}, b$ 。

步骤流程:

1. 初始化 $\mathbf{w}_0, b_0$ (随机或取 0)
2. 在数据集中选取数据 $(\mathbf{x}_i, y_i) (i = 1, 2, \dots, N)$
3. 设 $o_i = g(\mathbf{w}\mathbf{x}_i + b)$, 更新参数:

$$\mathbf{w} \leftarrow \mathbf{w} + \eta(y_i - o_i)g'(\mathbf{w}\mathbf{x}_i + b)\mathbf{x}_i$$

$$b \leftarrow b + \eta(y_i - o_i)g'(\mathbf{w}\mathbf{x}_i + b)$$

4. 转到 (2), 直到达到收敛条件 (如权重更新的相对差值小于阈值)。

同样可以计算先前的例子, 初值改为 $\mathbf{w}_0 = (0, 0), b_0 = 0$, g 用 sigmoid 函数, 只计算第一轮。

6 人工神经网络

6.1 激活函数

净输入 z 在经过一个非线性函数 $f(\cdot)$ 后，得到神经元的活性值，即 $y = f(z)$ ；其中的非线性函数 $f(\cdot)$ 称为激活函数。

激活函数在神经元模型中非常重要，需要具备以下性质

1. 连续且可导：可以允许少数点不可导
2. 计算效率：激活函数及导数要尽可能简单
3. 训练效率和稳定性：激活函数导数的值域要在合适的区间内，不能太大也不能太小、

常用的激活函数：阶跃函数、sigmoid 函数、tanh 函数和 ReLU 函数

6.1.1 阶跃函数

$$\text{sgn}(x) = I(x \geq 0)$$

阶跃函数具有不连续和不光滑等不太好的性质。

6.1.2 sigmoid 函数

$$\text{sigmoid}(x) = \frac{1}{1 + \exp(-x)}$$

输入值在 0 附近时，sigmoid 函数近似为线性函数；输入值远离 0 时，对输入值进行抑制。

其导数为 $\text{sigmoid}'(x) = \text{sigmoid}(x)[1 - \text{sigmoid}(x)]$ 。

优点：

- 方便求导。
- 能压缩数据，数据幅度不会有问题。
- 适合前向传播算法

缺点：

- 梯度消失：由于在反向传播算法（BP 算法）中，每一层误差更新时都要乘以激活函数的导数。而在输入值绝对值较大时，sigmoid 函数的导数接近于 0，结果导致每一层的误差很小，从而无法训练深度网络。
- 输出值域不是零均值的：导致反向传播过程中，总往一个方向更新，收敛速度缓慢。
- 计算耗时：存在幂运算。

6.1.3 tanh 函数

$$\tanh(x) = \frac{\exp(x) - \exp(-x)}{\exp(x) + \exp(-x)} = 2\text{sigmoid}(x) - 1$$

放大平移版的 sigmoid 函数，值域 $(-1, 1)$ ；导数为 $\tanh'(x) = \frac{4}{(\exp(x) + \exp(-x))^2}$ 。

优点：

- 解决了 sigmoid 非零均值的问题
- 完全可微，中心对称。

缺点：梯度消失和计算耗时。

6.1.4 ReLU 函数

目前神经网络中经常使用的激活函数，定义为： $ReLU(x) = \max(0, x)$ ，其导数就是阶跃函数。

优点：

- 左饱和函数（趋于负无穷时，导数为 0），且大于 0 时， $ReLU$ 函数的导数为 1，缓解了梯度消失问题。
- 计算速度快，收敛速度快。

缺点：

- 非零均值。
- 存在死亡 ReLU 问题：某次更新时，如果某个 ReLU 在所有训练数据上都不能被激活，那么其梯度永远会是 0，再也不会被激活。

6.2 前馈神经网络（FNN）

简单来说，就是一层层连接的神经网络。不存在同层连接，也不存在跨层连接（即第 1 层不能连接第 3 层）。




图 3: FNN 示意图

6.2.1 FNN 的组成

记号	含义
L	神经网络的层数, 只包含隐藏层和输出层
M_l	第 l 层神经元的个数
$f_l(\cdot)$	第 l 层神经元的激活函数
$\mathbf{W}^{(l)} \in \mathbb{R}^{M_{l-1} \times M_l}$	第 $l-1$ 层到第 l 层的权重矩阵
$\boldsymbol{\theta}^{(l)} \in \mathbb{R}^{M_l}$	第 $l-1$ 层到第 l 层的偏置
$\mathbf{z}^{(l)} \in \mathbb{R}^{M_l}$	第 l 层神经元的净输入(净活性值)
$\mathbf{b}^{(l)} \in \mathbb{R}^{M_l}$	第 l 层神经元的输出(活性值)

图 4: FNN 各层记号

FNN 共两个公式，我们记 $\mathbf{b}^{(0)} = \mathbf{x} = (x_1, x_2, \dots, x_p)^T$ ，一个信息传播过程（比如做预测）如下（前向传播，前馈计算）：

$$\begin{cases} \mathbf{z}^{(l)} = \mathbf{W}^{(l)T} \mathbf{b}^{(l-1)} - \boldsymbol{\theta}^{(l)} \\ \mathbf{b}^{(l)} = f_l(\mathbf{z}^{(l)}), \end{cases} \quad l = 1, \dots, L \quad (4)$$

实例：如何计算 FNN 的参数个数？




图 5: 两层 FNN

我们以 2 层 FNN 为例, p 个属于神经元, l 个输出神经元, q 个隐藏层神经元。其参数个数为 $(p+1)q + (q+1)l$, 如 $(p+1)$ 为隐藏层中每 1 个净输入的参数个数 (p 个权重 +1 个偏移项), 但是隐藏层有 q 个神经元, 所以还需要乘以 q 。第二项同理。

6.2.2 通用近似定理

为什么 FNN 可以被那么广泛的使用? 主要原因就是 1989 年证明的通用近似定理: 只需一个足够多神经元的隐藏层, FNN 就能以任意精度逼近任意复杂度的连续函数。这一定理表明 FNN 可以作为“万能函数”。

6.2.3 与机器学习的联系

FNN 可以看作是非线性复合函数 $f: R^p \rightarrow R^l$ 。

1. 特征提取 (降维): 由于 $R^p \rightarrow R^l$, 实际上神经网络可以将 p 维特征转换为 l 维特征, 实现了降维。
2. 分类问题: 特别地, 如果 $l = 1$, 且最后一层激活函数使用 *sigmoid* 函数, 其就是一个二分类模型; 如果 $l = 1$, 且最后一层激活函数使用 *softmax* 函数, 其就是一个多分类模型。

6.3 反向传播算法 (BP 算法)

假设训练集 D 的样本容量为 n , $D = \{(\mathbf{x}_i, y_i), i = 1, \dots, n\}$ 。风险函数为:

$$R(\mathbf{W}, \boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n l(y_i, \hat{y}_i) + \frac{1}{2} \lambda \|\mathbf{W}\|_F^2$$

$\|\mathbf{W}\|_F^2$ 为所有权重的平方和。 $l(\cdot, \cdot)$ 为损失函数。 λ 为正则化参数, 防止过拟合。

对于回归问题, $l(\cdot, \cdot)$ 为平方损失; 对于分类问题, $l(\cdot, \cdot)$ 为交叉熵损失。

学习参数的方法: 梯度下降法。

$$\mathbf{W}^{(l)} \leftarrow \mathbf{W}^{(l)} - \eta \left(\frac{1}{n} \sum_{i=1}^n \frac{\partial l(y_i, \hat{y}_i)}{\partial \mathbf{W}^{(l)}} + \lambda \mathbf{W}^{(l)} \right) \quad (5)$$

$$\boldsymbol{\theta}^{(l)} \leftarrow \boldsymbol{\theta}^{(l)} - \eta \left(\frac{1}{n} \sum_{i=1}^n \frac{\partial l(y_i, \hat{y}_i)}{\partial \boldsymbol{\theta}^{(l)}} \right) \quad (6)$$

η 为学习率 (或步长), 控制收敛速度。

6.3.1 BP 算法推导流程

现在以求解 $\frac{\partial l(y, \hat{y})}{\partial \mathbf{W}^{(l)}}$ 为例。为了书写简单，我们先求解： $\frac{\partial l(y, \hat{y})}{\partial w_{ij}^{(l)}} = \frac{\partial \mathbf{z}^{(l)}}{\partial w_{ij}^{(l)}} \frac{\partial l(y, \hat{y})}{\partial \mathbf{z}^{(l)}}$ ，注意 $\frac{\partial \mathbf{z}^{(l)}}{\partial w_{ij}^{(l)}}$ 是容易计算的，因为 $\mathbf{z}^{(l)}$ 实际上就是 w_{ij} 的线性组合；但后一项 $\frac{\partial l(y, \hat{y})}{\partial \mathbf{z}^{(l)}}$ 较难计算。反向传播算法就是快速计算 $\frac{\partial l(y, \hat{y})}{\partial \mathbf{z}^{(l)}}$ （称为误差项）的算法。

先计算简单的部分：注意到 $\mathbf{z}^{(l)} = \mathbf{W}^{(l)T} \mathbf{b}^{(l-1)} - \boldsymbol{\theta}^{(l)}$ ，从而 $z_i^{(l)} = \sum_{k=1}^{M_l} w_{ik} b_k^{(l-1)} - \theta_i^{(l)}$

$$\begin{aligned} \frac{\partial \mathbf{z}^{(l)}}{\partial w_{ij}^{(l)}} &= \left[\frac{\partial z_1^{(l)}}{\partial w_{ij}^{(l)}}, \dots, \frac{\partial z_i^{(l)}}{\partial w_{ij}^{(l)}}, \dots, \frac{\partial z_{M_l}^{(l)}}{\partial w_{ij}^{(l)}} \right] \\ &= [0, \dots, b_j^{(l-1)}, \dots, 0] \end{aligned}$$

同理，

$$\frac{\partial \mathbf{z}^{(l)}}{\partial \boldsymbol{\theta}^{(l)}} = -I_{M_l}$$

接下来进入反向传播算法的核心：计算误差项 $\boldsymbol{\delta}^{(l)} = \frac{\partial l(y, \hat{y})}{\partial \mathbf{z}^{(l)}} \in R^{M_l}$ 。

注意有 $\mathbf{b}^{(l)} = f_l(\mathbf{z}^{(l)})$ ， $\frac{\partial \mathbf{b}^{(l)}}{\partial \mathbf{z}^{(l)}} = \text{diag}(f'_l(\mathbf{z}^{(l)})) = \text{diag}\{f'_l(z_1^{(l)}), \dots, f'_l(z_{M_l}^{(l)})\} \in R^{M_l \times M_l}$ ；而 $\frac{\partial \mathbf{z}^{(l+1)}}{\partial \mathbf{b}^{(l)}} = \frac{\partial \mathbf{W}^{(l+1)T} \mathbf{b}^{(l)} - \boldsymbol{\theta}^{(l+1)}}{\partial \mathbf{b}^{(l)}} = \mathbf{W}^{(l+1)} \in R^{M_{l+1} \times M_l}$

由链式法则，我们有：

$$\begin{aligned} \boldsymbol{\delta}^{(l)} &= \frac{\partial l(y, \hat{y})}{\partial \mathbf{z}^{(l)}} = \frac{\partial \mathbf{b}^{(l)}}{\partial \mathbf{z}^{(l)}} \frac{\partial \mathbf{z}^{(l+1)}}{\partial \mathbf{b}^{(l)}} \frac{\partial l(y, \hat{y})}{\partial \mathbf{z}^{(l+1)}} \\ \boldsymbol{\delta}^{(l)} &= \text{diag}(f'_l(\mathbf{z}^{(l)})) \mathbf{W}^{(l+1)} \boldsymbol{\delta}^{(l+1)} \in R^{M_l} \end{aligned} \quad (7)$$

(6) 就是反向传播公式。所谓反向传播，即在更新误差项 $\boldsymbol{\delta}^{(l)}$ 时，先更新最外层的误差 $\boldsymbol{\delta}^{(L)}$ ，再通过上述公式一层层地向内更新 $\boldsymbol{\delta}^{(l)}$ ，这一过程正好和信息传播过程（如做预测）的方向相反，所以称为反向传播。

从这一公式可以明显看出 sigmoid 函数的梯度消失问题，如果某一层的 $\mathbf{z}^{(l)}$ 过大，那么对应的导数值接近 0，导致误差项为 0。

得到误差项之后，我们可以将前文的公式 (4)(5) 改写。

$$\frac{\partial l(y, \hat{y})}{\partial w_{ij}^{(l)}} = \frac{\partial \mathbf{z}^{(l)}}{\partial w_{ij}^{(l)}} \frac{\partial l(y, \hat{y})}{\partial \mathbf{z}^{(l)}} = b_j^{(l-1)} \delta_i^{(l)}$$

从而有：

$$\frac{\partial l(y, \hat{y})}{\partial \mathbf{W}^{(l)}} = \boldsymbol{\delta}^{(l)} \mathbf{b}^{(l-1)T} \quad (8)$$

同理，

$$\frac{\partial l(y, \hat{y})}{\partial \boldsymbol{\theta}^{(l)}} = -\boldsymbol{\delta}^{(l)} \quad (9)$$

6.3.2 BP 算法更新流程

整个神经网络更新的算法如下：

1. 初始化 $\mathbf{W}, \boldsymbol{\theta}$ ；给定 λ 和 η
2. 从样本集中选取样本 $(\mathbf{x}, y)$

3. 由
$$\begin{cases} \mathbf{z}^{(l)} = \mathbf{W}^{(l)T} \mathbf{b}^{(l-1)} - \boldsymbol{\theta}^{(l)} \\ \mathbf{b}^{(l)} = f_l(\mathbf{z}^{(l)}), \end{cases} \quad l = 1, \dots, L$$
 计算出每一层的 $\mathbf{z}^{(l)}$ 和 $\mathbf{b}^{(l)}$
4. 由 $\boldsymbol{\delta}^{(l)} = \text{diag}(f'_l(\mathbf{z}^{(l)})) \mathbf{W}^{(l+1)T} \boldsymbol{\delta}^{(l+1)}$ 计算出所有的误差项 $\boldsymbol{\delta}^{(l)}$ （最后一层的误差项 $\boldsymbol{\delta}^{(L)}$ 很容易计算，简单求导即可）
5. 用 $\mathbf{W}^{(l)} \leftarrow \mathbf{W}^{(l)} - \eta [\boldsymbol{\delta}^{(l)} \mathbf{b}^{(l-1)T} + \lambda \mathbf{W}^{(l)}]$ 和 $\boldsymbol{\theta}^{(l)} \leftarrow \boldsymbol{\theta}^{(l)} + \eta \boldsymbol{\delta}^{(l)}$ 更新参数。
6. 直到达到终止条件；否则回到第 2 步，继续更新参数。

6.3.3 预处理及初始化

预处理：将全部特征标准化或归一化，避免影响神经网络的权重参数更新

初始化 $\mathbf{W}, \boldsymbol{\theta}$ ：不把所有元素设为相同取值，可以从标准正态分布或均匀分布中随机抽样进行初始化。

6.4 神经网络的正则化

神经网络训练过程中，很容易过拟合，导致泛化能力较弱。

正则化的目的在于提高泛化能力，使其在测试集上的误差也较小。

6.4.1 早停法

提前停止训练，而不必等神经网络的损失函数达到最小值。实际训练中，将数据集分为训练集、验证集和测试集。




图 6: 早停法

如图，选择验证集上误差最小的点作为训练停止点，选此时的模型为最终模型。

6.4.2 暂退法 (Dropout)

在训练过程中，随机让一些神经元的激活值取 0，即让他们不参与训练。

训练时，设对于输入层和隐藏层（不包括输出层），每一层的神经元以概率 p 保留，以概率 $1 - p$ 退出。（每层的概率可以不同）

在训练的每一步，针对每一个样本或每一组样本，随机判断一次，得到子网络，用之前的方法更新子网络的权重。




图 7: 暂退法（部分神经元退出）

6.4.3 惩罚法

即目标函数的第二项 $\lambda \|\mathbf{W}\|_F^2$ ，限制模型的学习能力，防止过拟合

$$R(\mathbf{W}, \boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n l(y_i, \hat{y}_i) + \frac{1}{2} \lambda \|\mathbf{W}\|_F^2$$

6.5 实例

1. 输入层：2 个节点。
2. 隐藏层（只有一层）：2 个节点，激活函数为 sigmoid 函数。
3. 输出层：1 个节点，激活函数为 sigmoid 函数。

损失函数为 MSE，请推导出所有误差项。

已知这次更新的输入为 x_1, x_2 ，输出为 $\hat{y}$ ，真实值为 y 。初始的权重矩阵和偏差已知。

7 垂直平分分类器

线性分类器：使用线性决策边界 $w^T x + b = 0$ ，将数据划分为不同类别。

7.1 决策边界和分类规则

假设两类样本的均值分别为 $\mu_1 = \frac{1}{n_1} \sum_{i \in C_1} x_i, \mu_2 = \frac{1}{n_2} \sum_{i \in C_2} x_i$ ，则决策边界为：

$$w = \mu_1 - \mu_2, b = -\frac{1}{2}(\mu_1^T \mu_1 - \mu_2^T \mu_2)$$

决策函数为：

$$g(x) = w^T x + b$$

分类规则为：

$$\text{结果} = \begin{cases} 1 & g(x) > 0 \\ -1 & g(x) < 0 \end{cases}$$

问题：如何推导垂直平分分类器？

7.2 实例

如下图给出了一个二维的垂直平分分类器的实例。

- **已知**
 - 甲类：[0 3]^T、[2 4]^T、[1 3]^T、[2 3]^T、[0 2]^T
 - 乙类：[4 1]^T、[3 2]^T、[2 1]^T、[3 0]^T、[3 1]^T
 - **试问**
 - 使用 **垂直平分分类器**
 - 待分类样本为 $x = [5 0]^T$ ，问 x 应决策为哪一类？

图 8: 垂直平分分类器实例

7.3 特点

- 也叫最小距离分类器
- 不是最佳决策，没有使用准则函数求极值
- 最简单的算法
- 原则上对样本无特殊要求，仅适用于二分类

8 SVM 支持向量机

有监督的统计学习方法，广泛应用于分类和回归。主要目标：寻找一个超平面，使得它能够尽可能将两类数据点正确分开，同时使分开的两类数据点距离超平面最远。

这是一个约束二次规划问题。

8.1 超平面

超平面： $\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p = 0$ ，如果设 $\beta = (\beta_1, \dots, \beta_p)^T$ ，则超平面也可以表示成 $\beta_0 + \beta^T X = 0$ 。
对于空间中任意点 $\mathbf{x} = (x_1, \dots, x_p)$ ，其到超平面的距离为 $d = \frac{|\beta_0 + \beta^T \mathbf{x}|}{\|\beta\|_2}$ 。

对于新样本点 $\mathbf{x}^*$ ， $g(\mathbf{x}^*) = \beta_0 + \beta^T \mathbf{x}^*$ 。

如果 $g(\mathbf{x}^*)$ 的符号为正，则将 $\mathbf{x}^*$ 分为 1 类。

如果 $g(\mathbf{x}^*)$ 的符号为负，则将 $\mathbf{x}^*$ 分为-1 类。


进一步，如果 $g(\mathbf{x}^*)$ 取值远离 0，就能准确判断 $\mathbf{x}^*$ 属于的类别；否则就很难判断。

8.2 最大间隔分类器

最大间隔超平面，也叫最优分割超平面，是离训练样本最远的分割超平面。

间隔：计算训练集中每个样本到超平面的垂直距离，其中最小的距离叫做间隔 M。

寻找超平面中使得间隔最大的超平面，叫做最大间隔分类器。



实线是超平面，虚线是间隔，阴影部分为最大间隔宽度：
 $2M = 2/\|\beta\|_2$

图 9: 最大间隔示意图，最大间隔为 M（正负类间最大间隔为 2M）

最大间隔超平面就是求解下述优化问题：

$$\begin{cases} \max_{\beta, \beta_0} & M \\ \text{s.t.} & \|\beta\|_2 = 1, y_i(\beta_0 + \beta^T \mathbf{x}_i) \geq M \quad i = 1, 2, \dots, n \end{cases} \quad (10)$$

- 在 $\|\beta\|_2 = 1$ 的条件下， $y_i(\beta_0 + \beta^T \mathbf{x}_i)$ 就是数据点到分割超平面的距离。如果 $M > 0$ ，那么确保每个观测都落在超平面的正确一侧，同时要求和超平面间保持一定的距离。

上面的优化问题可以转化为下述：

$$\begin{cases} \min_{\beta, \beta_0} & \frac{1}{2} \|\beta\|_2^2 \\ \text{s.t.} & y_i(\beta_0 + \beta^T \mathbf{x}_i) \geq 1 \quad i = 1, 2, \dots, n \end{cases}$$

通过拉格朗日乘子法，可以求解这一优化问题。

$$L(\boldsymbol{\beta}, \beta_0; \boldsymbol{\lambda}) = \frac{1}{2} \|\boldsymbol{\beta}\|_2^2 - \sum_{i=1}^n \lambda_i [y_i(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i) - 1]$$

$L(\boldsymbol{\beta}, \beta_0; \boldsymbol{\lambda})$ 分别对 $\boldsymbol{\beta}, \beta_0$ 求偏导数，并令其等于 0，可以得到

$$\boldsymbol{\beta} = \sum_{i=1}^n \lambda_i y_i \mathbf{x}_i, 0 = \sum_{i=1}^n \lambda_i y_i$$

其中前面这个式子非常的关键。我们可以据此得到最后分割超平面的形式

$$g(\mathbf{x}) = \beta_0 + \boldsymbol{\beta}^T \mathbf{x} = \beta_0 + \sum_{i=1}^n \lambda_i y_i \mathbf{x}_i^T \mathbf{x}$$

并且最优的 $(\boldsymbol{\beta}, \beta_0; \boldsymbol{\lambda})$ 还要符合 KKT 条件：

$$\begin{cases} \lambda_i & \geq 0 \\ y_i(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i) - 1 & \geq 0 \\ \lambda_i [y_i(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i) - 1] & = 0 \end{cases}$$

对这个 KKT 条件，我们做如下说明：

- 对任意的样本，要么其为支持向量 ($y_i(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i) - 1 = 0$)，要么其远离分割平面 ($y_i(\beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i) - 1 > 0$)。
- 对于原理分割平面的样本点，其 $\lambda_i = 0$ ，对 $g(\mathbf{x}) = \beta_0 + \sum_{i=1}^n \lambda_i y_i \mathbf{x}_i^T \mathbf{x}$ 没有任何任何影响，被称为安全点。
- 对于支持向量来说， $\lambda_i > 0$ ，其会影响 $g(\mathbf{x})$ 。

最终得到的对偶问题如下：

$$\begin{cases} \max_{\boldsymbol{\lambda}} & \{ \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{k=1}^n \lambda_i \lambda_k y_i y_k \mathbf{x}_i^T \mathbf{x}_k \} \\ \text{s.t.} & 0 = \sum_{i=1}^n \lambda_i y_i, \lambda_i \geq 0, i = 1, 2, \dots, n \end{cases}$$

其中 $\mathbf{x}_i^T \mathbf{x}_k$ 为内积，可以记为 $\langle \mathbf{x}_i, \mathbf{x}_k \rangle$ 。

假设该对偶问题求解出的最优解为 $\hat{\boldsymbol{\lambda}} = (\hat{\lambda}_1, \dots, \hat{\lambda}_n)^T$ ，则 $\boldsymbol{\beta}$ 的估计为：

$$\hat{\boldsymbol{\beta}} = \sum_{i=1}^n \hat{\lambda}_i y_i \mathbf{x}_i$$

而对于 β_0 的估计，可以通过支持向量来求解，设 $(\mathbf{x}_s, y_s)$ 为任意支持向量，则有：

$$\hat{\beta}_0 = \frac{1}{y_s} - \hat{\boldsymbol{\beta}}^T \mathbf{x}_s$$

当然也可以用稳健一点的估计，即

$$\hat{\beta}_0 = \frac{1}{|S|} \sum_{s \in S} \left\{ \frac{1}{y_s} - \hat{\boldsymbol{\beta}}^T \mathbf{x}_s \right\}$$

其中 S 是支持向量的集合。

8.3 支持向量分类器

也成为软间隔分类器，允许观测落在间隔错误的一侧（即间隔内），甚至超平面错误的一侧。




图 10: 支持向量分类器示意图

即将前文 (10) 的优化问题转化为:

$$\begin{cases} \max_{\beta, \beta_0, \epsilon} & M \\ \text{s.t.} & \|\beta\|_2 = 1, y_i(\beta_0 + \beta^T \mathbf{x}_i) \geq M(1 - \epsilon_i), \epsilon_i \geq 0, \sum_{i=1}^n \epsilon_i \leq C, i = 1, 2, \dots, n \end{cases} \quad (11)$$

这里 $\epsilon = (\epsilon_1, \dots, \epsilon_n)^T$ 被称为松弛变量，允许样本中有一小部分落在间隔错误的一侧或超平面错误的一侧。

- $\epsilon_i = 0$ ，样本在间隔上或间隔正确的一侧。
- $0 < \epsilon_i < 1$ ，样本在间隔错误的一侧，但分类仍正确
- $\epsilon_i = 1$ ，样本在超平面上。
- $\epsilon_i > 1$ ，样本在超平面错误的一侧。




图 11: 松弛变量的解释

对于调节参数 C 来说，如果 $C = 0$ ，就是最大间隔分类器；随着 C 的增加，越允许部分样本点穿过间隔，间隔会变得越来越宽。

类似地，可以将 (11) 的优化问题转化为

$$\begin{cases} \min_{\beta, \beta_0, \epsilon} & \frac{1}{2} \|\beta\|_2^2 + \alpha \sum_{i=1}^n \epsilon_i \\ \text{s.t.} & y_i(\beta_0 + \beta^T \mathbf{x}_i) \geq 1 - \epsilon_i, \epsilon_i \geq 0, i = 1, 2, \dots, n \end{cases}$$

对偶问题为：

$$\begin{cases} \max_{\lambda} & \left\{ \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{k=1}^n \lambda_i \lambda_k y_i y_k \mathbf{x}_i^T \mathbf{x}_k \right\} \\ \text{s.t.} & 0 = \sum_{i=1}^n \lambda_i y_i, 0 \leq \lambda_i \leq \alpha, i = 1, 2, \dots, n \end{cases}$$

实例：给定下述数据集，请写出支持向量分类器（软间隔）下需要求解的具体优化问题（要求对偶形式，核函数即线性核函数）。

表 6: 支持向量分类器实例

x_1	x_2	y
1	1	1
2	2	1
2	0	-1
0	0	-1

8.4 核函数

8.4.1 引入核函数

对于非线性决策边界，直接用 SVM 的效果非常不好，这时要使用核函数来扩大特征空间。即给定一个基函数 $\mathbf{b}(\mathbf{x}) \in R^L$ ，使得模型变为

$$g(\mathbf{x}) = \beta_0 + \beta^T \mathbf{b}(\mathbf{x})$$

这时候支持向量机求解的问题变为：

$$\begin{cases} \min_{\beta, \beta_0, \epsilon} & \frac{1}{2} \|\beta\|_2^2 + \alpha \sum_{i=1}^n \epsilon_i \\ \text{s.t.} & y_i(\beta_0 + \beta^T \mathbf{b}(\mathbf{x}_i)) \geq 1 - \epsilon_i, \epsilon_i \geq 0, i = 1, 2, \dots, n \end{cases}$$

对偶问题变为：

$$\begin{cases} \max_{\lambda} & \left\{ \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{k=1}^n \lambda_i \lambda_k y_i y_k \mathbf{b}(\mathbf{x}_i)^T \mathbf{b}(\mathbf{x}_k) \right\} \\ \text{s.t.} & 0 = \sum_{i=1}^n \lambda_i y_i, 0 \leq \lambda_i \leq \alpha, i = 1, 2, \dots, n \end{cases}$$

$\mathbf{b}(\mathbf{x}_i)^T \mathbf{b}(\mathbf{x}_k)$ 实际上还是两者内积，只不过是映射到高维空间后做内积。但是这个内积可能不好求，特别是在维数很高的情况下，所以我们引入核函数 $K(\cdot, \cdot)$ ，使得问题变为：

$$\begin{cases} \max_{\lambda} & \left\{ \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{k=1}^n \lambda_i \lambda_k y_i y_k K(\mathbf{x}_i, \mathbf{x}_k) \right\} \\ \text{s.t.} & 0 = \sum_{i=1}^n \lambda_i y_i, 0 \leq \lambda_i \leq \alpha, i = 1, 2, \dots, n \end{cases}$$

最后的模型变为：

$$g(\mathbf{x}) = \hat{\beta}_0 + \hat{\beta}^T \mathbf{b}(\mathbf{x}) = \hat{\beta}_0 + \sum_{i=1}^n \hat{\lambda}_i y_i K(\mathbf{x}, \mathbf{x}_i)$$

8.4.2 常见的核函数

- 线性核函数 $K(\mathbf{x}_i, \mathbf{x}_k) = \langle \mathbf{x}_i, \mathbf{x}_k \rangle$ ，就是向量内积。
- 自由度为 d 的多项式核函数： $K(\mathbf{x}_i, \mathbf{x}_k) = (1 + \langle \mathbf{x}_i, \mathbf{x}_k \rangle)^d$

- 径向核函数: $\mathbf{K}(\mathbf{x}_i, \mathbf{x}_k) = \exp\left(-\gamma \sum_{j=1}^p (x_{ij} - x_{kj})^2\right)$, γ 为正常数
- sigmoid 核函数: $\mathbf{K}(\mathbf{x}_i, \mathbf{x}_k) = \tanh(\gamma \langle \mathbf{x}_i, \mathbf{x}_k \rangle + \theta)$, γ 为正常数, θ 为负常数。

9 图像特征提取

9.1 图像基本概念

图像是什么：二维矩阵 $I(x, y) \in R^{M \times N}$ ，其中 M, N 为图像的高度和宽度，即分辨率。

图像以像素为单位。 $I(x, y)$ 表示位于 (x, y) 的像素值。

常见的有 8 位灰度图像（8 位二进制数，即 0-255）和 24 位彩色图像 (RGB)。

对于灰度图像来说， $I(x, y)$ 越大，则越接近白色； $I(x, y)$ 越小，越接近黑色。

静态彩色图像可以看作三个二维数组，即三个通道。

9.2 图像特征基本概念

图像特征是从原始数据中提取的关键描述信息。常见的特征有颜色、纹理、边缘、形状等。

- 颜色是其他特征的基础，纹理和边缘都依赖于颜色或灰度的变化。
- 纹理和边缘往往出现在颜色变化较大的区域。
- 形状是基于边缘特征提取的高层次信息，用于识别物体和场景。

9.3 颜色特征提取

9.3.1 颜色直方图

颜色直方图是最常见的颜色特征提取方法之一，通过像素值分布来表征图像的颜色信息，是**全局特征**。

假设图像 I ，其颜色分布为 $p(c)$, c 表示像素。颜色直方图定义为：

$$Freq(c) = \sum_{x,y} 1(I(x, y) = c), p(c) = \frac{Freq(c)}{N}$$

也可以考虑划分为区间，即 $Freq(a, b) = \sum_{x,y} 1(a \leq I(x, y) \leq b)$;

优点：简单易算，适用于不同分辨率的图像。适用于图像检索、分类等。

实例：请计算不同通道的颜色直方图（24 位按照 RGB 排列）的频次 $Freq(c)$ （ c 转换为 0-255）：

表 7: 颜色直方图（和颜色矩）实例

11111111 00000000 00000000	00000000 11111111 00000000	00000000 00000000 11111111
11111111 11111111 00000000	00000000 11111111 11111111	11111111 00000000 11111111
00000000 00000000 00000000	10000000 10000000 10000000	11111111 11111111 11111111

颜色特征提取示例



图: 灰度图像




图: 对应的颜色直方图

图 12: 颜色直方图实例

9.3.2 颜色矩

颜色矩用于描述图像颜色分布的统计特征，通常计算一阶矩、二阶矩和三阶矩。

N 是像素总数， p_{ij} 是第 j 个像素在第 i 个通道上的值。

- 一阶矩: $E_i = \frac{1}{N} \sum_{j=1}^N p_{ij}$
- 二阶矩: $\sigma_i^2 = \frac{1}{N} \sum_{j=1}^N (p_{ij} - E_i)^2$
- 三阶矩: $s_i = \frac{1}{N} \sum_{j=1}^N (p_{ij} - E_i)^3$

颜色矩适用于颜色分布的低维表征，适用于纹理识别、场景分类等任务。

与直方图比较：直方图适合快速匹配，颜色矩提供了更为准确的统计信息，适用于更复杂的任务。

实例：请基于前表，计算三个通道的一阶矩和二阶矩。

9.4 纹理特征提取

纹理反映了图像中像素强度的局部变化，描述物体的表面结构。

9.4.1 灰度共生矩阵 (GLCM)

对于一副图像 I ，灰度共生矩阵 $P(i, j)$ 的计算方法如下：

$$P_{\Delta x, \Delta y}(i, j) = \sum_{x=1}^N \sum_{y=1}^M \begin{cases} 1 & I(x, y) = i \text{ 且 } I(x + \Delta x, y + \Delta y) = j \\ 0 & \text{否则} \end{cases}$$

其中 $(x + \Delta x, y + \Delta y)$ 为相对 (x, y) 的位移，可等价替换为距离 d 和角度 θ 确定（反向极坐标）。

如： $(d, \theta) = (1, 0)$ 等价于 $(\Delta x, \Delta y) = (1, 0)$ ； $(d, \theta) = (\sqrt{2}, \frac{\pi}{4})$ 等价于 $(\Delta x, \Delta y) = (1, 1)$

实例：试计算下列图像的 GLCM ((i, j) 从 $(0, 0)$ 开始)。

下图展示了一个简单的 4×4 灰度图像：

$$\begin{bmatrix} 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 \\ 2 & 2 & 3 & 3 \\ 2 & 2 & 3 & 3 \end{bmatrix}$$

计算对应的 GLCM.

图 13: GLCM 实例

(1) $(d, \theta) = (1, 0)$

(2) $(d, \theta) = (1, \frac{\pi}{2})$

得到 GLCM 矩阵后，有一些值可以计算：

- 能量: $Energy = \sum_i \sum_j P^2(i, j)$ ，值越高图像纹理越规则或均匀。
- 对比度: $Contrast = \sum_i \sum_j (i - j)^2 P(i, j)$ ，值越高表示纹理变化剧烈，灰度值差异较大。
- 熵: $Entropy = - \sum_i \sum_j P(i, j) \log(P(i, j))$ ，值越高表示纹理越复杂，灰度分布越不均匀。

实例：基于之前 $(d, \theta) = (1, 0)$ 得到的 GLCM，计算能量和对比度。

9.4.2 局部二值模式 (LBP)

基本思想：比较中心像素与其邻域像素的灰度值，将邻域像素编码为二进制数，然后将二进制数组合成一个局部模式。

$$LBP(x_c, y_c) = \sum_{p=0}^{P-1} s(g_p - g_c) 2^p$$

g_c 是中心像素值， g_p 是邻域像素值， $s(x) = I(x \geq 0)$ 。(一般从左上角开始计算)

得到 LBP 图之后，再画出直方图。

实例：试计算下列图像的 LBP 矩阵（忽略边界像素），并画出频数直方图。

表 8: LBP 计算实例

10	12	14	13	10
11	25	24	22	12
15	30	28	27	14
14	20	18	17	12
10	13	12	11	9

LBP 跳变：跳变次数 $J = \sum_{i=1}^{P-1} |b_i - b_{i+1}| + |b_p - b_1|$ ， $b_i \in \{1, 0\}$ 表示第 i 个邻域像素的二值编码。表示相邻像素从 0 到 1 或从 1 到 0 的变化次数。跳变是衡量邻域像素灰度模式变化的重要现象，有助于捕捉边缘信息和局部纹理变化。较高的跳变次数通常对应着图像中的边缘或复杂纹理例：如 01100100，则跳变次数为 4。

LBP 具有灰度（光照）不变性：图像特征在不同光照条件下不发生变化。即 $f(I(x, y)) = f(I(x, y) + c)$ ，对于 LBP 函数来说成立。这一特点使得 LBP 在处理光照变化时有较强的鲁棒性，能处理人脸识别、纹理分析、图像检索等任务。

LBP 不具有旋转不变性，但改进后的 LBP 具有旋转不变性（图像旋转后，特征保持不变）。

9.5 边缘特征提取

图像边缘是像素强度发生显著变化的区域，通常表示物体的轮廓或者边界。边缘检测常常通过计算**图像梯度**来实现。在平坦区（灰度不变）梯度为零；边缘（灰度变化区域）梯度为非零。

梯度是图像中像素灰度值变化的方向和强度。梯度采用导数的离散近似。

图像的梯度通常使用卷积来计算： $(f * g)(x, y) = \sum_i \sum_j g(i, j) f(x - i, y - j)$ 。这里 $f(x, y)$ 是输入图像， $g(i, j)$ 是卷积核。计算示例如下（其中 K 是卷积核）：




图 14: 卷积计算示例

常见简单的卷积核：

- 两点差分算子： $G_1 = [-1, 1], G_2 = [-1, 1]^T$
- 两点差分算子（平滑版）： $G_1 = [-1, 0, 1], G_2 = [-1, 0, 1]^T$
- 三点二阶差分算子（二阶导）： $G_1 = [-1, 2, 1], G_2 = [-1, 2, 1]^T$

9.5.1 Roberts 算子

也叫交错差分算子，用对角方向的差分检测边缘。检测图像锐利边缘。

$$G_1 = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix}, G_2 = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$$

9.5.2 Prewitt 算子

水平和垂直梯度，适用于边缘平滑，噪声较少的图像。

$$G_1 = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix}, G_2 = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix}$$

9.5.3 Sobel 算子

Prewitt 算子的基础上加权的版本，增强了对噪声的鲁棒性。

$$G_1 = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}, G_2 = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}$$

9.5.4 Laplace 算子

有效捕捉图像中的所有边缘，尤其是尖锐边缘和快速灰度变化区域。对边缘方向不敏感。

$$G_{Laplace} = \begin{bmatrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{bmatrix}$$

实例：如下表，用两点差分算子梯度大小和方向，Laplace 算子分别算出其梯度大小。

表 9: 卷积计算实例

10	10	10	10	10
10	20	20	20	10
10	20	30	20	10
10	20	20	20	10
10	10	10	10	10

9.5.5 一些其它算法

1. HOG 算法

- (a) 方向梯度直方图 (HOG) 通过计算局部图像区域中的梯度方向分布，提取图像的纹理和边缘信息。
- (b) 方法如下：将图像划分为小单元，在每个单元中计算梯度方向的直方图（直方图横轴：角度），将直方图拼接在一起形成特征向量。

2. SIFT 特征

- (a) 具有尺度不变性和旋转不变性。使用高斯差分，按照梯度直方图分配主要方向，保证旋转不变性。

3. Canny 边缘检测

- (a) 使用 Sobel 算子计算梯度，设置阈值将梯度分为强边缘和弱边缘。

9.6 形状特征提取

形状特征描述图像中物体的外形、轮廓等几何特征。本节最主要介绍 Hough 变换。

9.6.1 Hough 变换

Hough 变换的基本思想是：把点是否共线问题转换为线是否共点（相交）。即把点映射到参数空间中，并寻找在参数空间中的聚集点。




图 15: Hough 变换基本思想

步骤如下:

1. 将图像 I 中的每个像素 (x, y) 映射到参数空间:

$$y = mx + b \Rightarrow \rho = x \cos \theta + y \sin \theta$$

2. 在参数空间 (ρ, θ) 中寻找峰值 (聚集点), 再还原回原空间, 即得到多点共线的直线方程。

注意, 没有必要遍历 (ρ, θ) 去寻找极大值, 可以使用累积器。即对每个像素 (x, y) , 计算得到 (ρ, θ) , 并将 (ρ, θ) 放入累积器中; 如此往复, 累积器中局部极大值的位置就对应原空间 (图像) 中多点共线的直线。

9.6.2 实例

对于点 $(1, 2), (2, 3), (3, 4)$, 用 Hough 变换判断他们是否共线; 若共线, 求出直线方程。

9.6.3 其它 Hough 变换

Hough 变换, 如果遇到参数空间的维度较高, 会导致较大的计算量。

- 概率 Hough 变换: 随机选取部分边缘点, 减少计算量。
- 广义 Hough 变换: 用于检测任意形状物体, 不只是直线和圆形。

10 判别分析

判别分析：使用具有类别信息的观测数据建立起一个分类器或者分类准则，以最大可能区分事先定义的类；实际应用中，常和分类混在一起。

个人理解：判别分析与分类不同的是，其更在乎模型和公式，更追求数学化的表达。

10.1 两个总体的贝叶斯判别方法

10.1.1 判别准则

对新样本 $\mathbf{x}_0$ 进行分类时，我们需要已知三个要素：

1. 两个总体密度函数在 $\mathbf{x}_0$ 处的比值 $\frac{f_1(\mathbf{x}_0)}{f_2(\mathbf{x}_0)}$ （未知时用样本估计）
2. 错判损失 $\frac{C(1|2)}{C(2|1)}$ （未知时用 1 替代或样本估计）
3. 先验概率 $\frac{q_2}{q_1}$ （未知时用 1 替代或样本估计）

判别准则为：

$$R_1 = \{\mathbf{x}, \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} \geq \frac{C(1|2) q_2}{C(2|1) q_1}\}$$
$$R_2 = \{\mathbf{x}, \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} < \frac{C(1|2) q_2}{C(2|1) q_1}\}$$

理论上，以上的贝叶斯判别准则是一个黄金的判别准则。

10.1.2 实例

已知错判损失分别为 $C(1|2) = 4, C(2|1) = 2$ ，先验概率为 $q_1 = 0.4, q_2 = 0.6$ 。对于新样本 $\mathbf{x}_0$ ，其密度函数分别为 $f_1(\mathbf{x}) = 0.7, f_2(\mathbf{x}) = 0.3$ ，用贝叶斯判别准则判别其属于总体 1 还是总体 2。

10.2 两个多元正态分布（同方差）的线性判别方法 LDA

10.2.1 判别准则

对于新观测数据 $\mathbf{x}$ ，有以下的 Fisher 线性判别函数（LDA）：

$$W(\mathbf{x}) = \mathbf{x}^T \boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) - \frac{1}{2}(\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2)^T \boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$$

大多数情况下， $\boldsymbol{\mu}$ 和 $\boldsymbol{\Sigma}$ 都是未知的，那么可以用样本值来替代：

$$W(\mathbf{x}) = \mathbf{x}^T \mathbf{S}^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2) - \frac{1}{2}(\bar{\mathbf{x}}_1 + \bar{\mathbf{x}}_2)^T \mathbf{S}^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)$$

（这公式怎么记呢？实际上可以查看上一节的垂直平分分类器，这里就是在垂直平分分类器的基础上增加了协方差矩阵的逆 $\mathbf{S}^{-1}$ ）

其中 $\mathbf{S} = \frac{\mathbf{V}^{(1)} + \mathbf{V}^{(2)}}{n_1 + n_2 - 2}$, $\mathbf{V}^{(k)} = \sum_{i=1}^{n_k} (\mathbf{x}_i^{(k)} - \bar{\mathbf{x}}^{(k)})(\mathbf{x}_i^{(k)} - \bar{\mathbf{x}}^{(k)})^T (k = 1, 2)$, $\mathbf{V}^{(k)}$ 称为样本的离差矩阵。
则判别准则如下：

$$R_1 = \{\mathbf{x}, W(\mathbf{x}) \geq \log k\}$$

$$R_2 = \{\mathbf{x}, W(\mathbf{x}) < \log k\}$$

其中 $k = \frac{C(1|2) q_2}{C(2|1) q_1}$ （是不是很熟悉，就是刚刚贝叶斯判别准则的右侧）

一样地，错判损失和先验概率用样本估计或者设为 1。

10.2.2 实例

已知错判损失分别为 $C(1|2) = 4, C(2|1) = 2$, 先验概率为 $q_1 = 0.4, q_2 = 0.6$ 。对于新样本 $\mathbf{x}_0 = [1, 3]^T$, 考虑其是属于总体 1: $\mu_1 = [2, 3]^T$, 还是总体 2: $\mu_2 = [5, 6]^T$, 两个总体的协方差矩阵均为: $\Sigma = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix}$, 用 Fisher 线性判别函数对新样本进行判别。

10.2.3 模型优缺点

并不能保证错判平均损失 $ECM = C(2|1)P(2|1, R)q_1 + C(1|2)P(1|2, R)q_2$ 达到最小; 但大样本情况下, 判别准则渐进最优。

10.3 两个同方差总体的 Fisher 判别方法 (Fisher LDA)

10.3.1 判别准则

其实 Fisher 判别就是前一节中 $k = 1$ 的情况, 但需要重新写一下符号:

设 $\hat{\xi}^T = \hat{a}S^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)$, 其中 $\hat{a}$ (为正数) 是为了使得 $\hat{\xi}^T$ 的长度为单位长度。

再设 $m = \frac{1}{2}\hat{a}(\bar{\mathbf{x}}_1 + \bar{\mathbf{x}}_2)^T S^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2) = \frac{1}{2}\hat{\xi}^T S^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)$ 。

判别准则如下:

$$R_1 = \{\mathbf{x}, y = \hat{\xi}^T \mathbf{x} \geq m\}$$

$$R_2 = \{\mathbf{x}, y = \hat{\xi}^T \mathbf{x} < m\}$$

10.3.2 判别准则要求

不需要假设总体来自正态分布, 但需要两个总体拥有相同的协方差矩阵。原理是, 将向量 $\mathbf{x}$ 投影到某个方向上, 使得离差的数学期望达到最大。

10.3.3 实例

(前年期末考了类似的题) 假设两个总体具有相同的协方差矩阵, 请用 Fisher 判别方法判断新样本点 $\mathbf{x}_0 = [4, 4]^T$ 来自总体 1 还是总体 2。

表 10: Fisher 判别方法实例

总体	x_1	x_2
1	2	3
1	3	3
1	2	4
2	5	6
2	6	5
2	5	5

10.4 两个多元正态分布 (异方差) 的二次判别方法 (QDA)

10.4.1 判别准则

对于新观测数据 $\mathbf{x}$, 有以下的二次判别函数 (LDA):

$$\delta(\mathbf{x}) = -\frac{1}{2}\mathbf{x}^T(\boldsymbol{\Sigma}_1^{-1} - \boldsymbol{\Sigma}_2^{-1})\mathbf{x} + (\boldsymbol{\mu}_1^T \boldsymbol{\Sigma}_1^{-1} - \boldsymbol{\mu}_2^T \boldsymbol{\Sigma}_2^{-1})\mathbf{x} - \zeta$$

其中, $\zeta = \frac{1}{2}\log(\frac{|\boldsymbol{\Sigma}_1|}{|\boldsymbol{\Sigma}_2|}) + \frac{1}{2}(\boldsymbol{\mu}_1^T \boldsymbol{\Sigma}_1^{-1} \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2^T \boldsymbol{\Sigma}_2^{-1} \boldsymbol{\mu}_2)$ 。由于 $\delta(\mathbf{x})$ 的第一项是二次的, 所以这一函数被称为二次判别函数。则判别准则:

$$R_1 = \{\mathbf{x}, \delta(\mathbf{x}) \geq \log k\}$$

$$R_2 = \{\mathbf{x}, \delta(\mathbf{x}) < \log k\}$$

其中 $k = \frac{C(1|2) q_2}{C(2|1) q_1}$ 。一样地, 错判损失和先验概率用样本估计或者设为 1。

参数未知时, 用样本值代替, 如 $\hat{\boldsymbol{\Sigma}}_1 = \frac{1}{n_1-1} \sum_{i=1}^{n_1} (\mathbf{x}_i^{(1)} - \bar{\mathbf{x}}^{(1)})(\mathbf{x}_i^{(1)} - \bar{\mathbf{x}}^{(1)})^T$

10.5 先验概率未知时, 到底如何估计

考虑协方差矩阵相等的情况, 先验概率未知时, 则 $\log k = c$ 未知, 为了进行判别分析, 关键是如何确定 c 。

记 $\Delta^2 = (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$, 选择 c 使得:

$$C(1|2) \int_{(c+\Delta^2/2)/\Delta}^{\infty} \frac{1}{\sqrt{2\pi}} \exp(-y^2/2) dy = C(2|1) \int_{-\infty}^{(c-\Delta^2/2)/\Delta} \frac{1}{\sqrt{2\pi}} \exp(-y^2/2) dy$$

特别地, 如果 $C(1|2) = C(2|1)$, 则 $c = 0$ 。

10.6 分类效果的评价——TPM

密度函数已知的情况下, 总的错判概率 TPM:

$$TPM = q_1 \int_{R_2} f_1(x) dx + q_2 \int_{R_1} f_2(x) dx$$

当密度函数未知时, 则需要计算实际错误率 AER 来评价, 如混淆矩阵、正确率、ROC 曲线等。

注: 潘斌没详细讲过多总体的判别分析, 即以下:

10.7 多个总体的贝叶斯判别方法

10.7.1 判别准则

对新样本 $\mathbf{x}_0$ 进行分类时, 对所有的总体 $i = 1, 2, \dots, J$, 计算:

$$\sum_{k=1, k \neq i}^J q_k f_k(\mathbf{x}) C(i|k)$$

取可以使上式达到最小的 i 作为预测。

如果不考虑错判损失, 则只需要考虑下式, 使得下式最大的 i 作为预测:

$$q_i f_i(\mathbf{x})$$

10.7.2 实例

如下图, 用贝叶斯判别方法, 判断新样本点 $\mathbf{x}_0$ 属于哪个总体?

		正确的总体		
		π_1	π_2	π_3
判归为:	π_1	$C(1 1) = 0$	$C(1 2) = 500$	$C(1 3) = 100$
	π_2	$C(2 1) = 10$	$C(2 2) = 0$	$C(2 3) = 50$
	π_3	$C(3 1) = 50$	$C(3 2) = 200$	$C(3 3) = 0$
先验概率		$q_1 = 0.05$	$q_2 = 0.60$	$q_3 = 0.35$
$\mathbf{x}_0$ 的密度值		$f_1(\mathbf{x}_0) = 0.01$	$f_2(\mathbf{x}_0) = 0.85$	$f_3(\mathbf{x}_0) = 2$

图 16: 多个总体的贝叶斯判别方法实例

- (1) 考虑错判损失，进行判别。
- (2) 不考虑错判损失，进行判别。

10.8 多个多元正态分布（异方差）的二次判别方法 QDA

定义第 j 个总体的二次判别得分函数为：

$$d_j(x) = -\frac{1}{2} \log |\Sigma_j| - \frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_j)^T \Sigma_j^{-1} (\mathbf{x} - \boldsymbol{\mu}_j) + \log(q_j)$$

$(\mathbf{x} - \boldsymbol{\mu}_j)^T \Sigma_j^{-1} (\mathbf{x} - \boldsymbol{\mu}_j)$ 称为马氏距离得分，得分函数最大的总体就是预测总体。未知参数用样本估计。

10.9 多个多元正态分布（同方差）的线性判别方法 LDA

10.9.1 判别方法

假设错判损失都相等，定义第 j 个总体（共 J 个）的二次判别得分函数为：

$$d_j(x) = \boldsymbol{\mu}_j^T \Sigma^{-1} \mathbf{x} - \frac{1}{2} \boldsymbol{\mu}_j^T \Sigma^{-1} \boldsymbol{\mu}_j + \log(q_j)$$

得分函数最大的总体就是预测总体。

未知参数用样本估计，如 $\hat{\Sigma} = \frac{1}{n-J} \sum_{j=1}^J \sum_{i=1}^{n_j} (\mathbf{x}_i^{(j)} - \bar{\mathbf{x}}^{(j)})(\mathbf{x}_i^{(j)} - \bar{\mathbf{x}}^{(j)})^T$ 。

10.9.2 实例

假设先验概率 $q_1 = q_2 = 0.25, q_3 = 0.5$ ，试使用下述样本建立 LDA 判别得分函数，并对新的样本 $\mathbf{x}_0 = [-2, -1]^T$ 进行分类。

例子：假设样本来自于三个二元正态总体 π_1, π_2 和 π_3 ，且假设三个正态总体有相同的协方差矩阵。

$$\begin{aligned} \pi_1: \mathbf{X}^{(1)} &= \begin{pmatrix} -2 & 5 \\ 0 & 3 \\ -1 & 1 \end{pmatrix}, \quad \bar{\mathbf{x}}^{(1)} = \begin{pmatrix} -1 \\ 3 \end{pmatrix}, \quad \mathbf{S}^{(1)} = \begin{pmatrix} 1 & -1 \\ -1 & 4 \end{pmatrix}; \\ \pi_2: \mathbf{X}^{(2)} &= \begin{pmatrix} 0 & 6 \\ 2 & 4 \\ 1 & 2 \end{pmatrix}, \quad \bar{\mathbf{x}}^{(2)} = \begin{pmatrix} 1 \\ 4 \end{pmatrix}, \quad \mathbf{S}^{(2)} = \begin{pmatrix} 1 & -1 \\ -1 & 4 \end{pmatrix}; \\ \pi_3: \mathbf{X}^{(3)} &= \begin{pmatrix} 1 & -2 \\ 0 & 0 \\ -1 & -4 \end{pmatrix}, \quad \bar{\mathbf{x}}^{(3)} = \begin{pmatrix} 0 \\ -2 \end{pmatrix}, \quad \mathbf{S}^{(3)} = \begin{pmatrix} 1 & 1 \\ 1 & 4 \end{pmatrix}. \end{aligned}$$

图 17: 多个总体的 LDA 判别实例

（只要求解出得分函数的形式即可，带入可以用计算器计算）

10.9.3 另一种判别方法

$$R_j = \{\mathbf{x}, u_{jk}(\mathbf{x}) > \log \frac{q_k}{q_j}, k = 1, \dots, J, k \neq j\}$$

其中 $u_{jk}(\mathbf{x}) = [\mathbf{x} - \frac{1}{2}(\boldsymbol{\mu}_j + \boldsymbol{\mu}_k)]^T \Sigma^{-1} (\boldsymbol{\mu}_j - \boldsymbol{\mu}_k)$ ，未知参数用样本估计

10.10 多个总体（同方差）的 Fisher 判别方法（Fisher LDA）

10.10.1 判别方法

定义总均值 $\bar{\mathbf{x}} = \frac{1}{J} \sum_{j=1}^J \bar{\mathbf{x}}^{(j)}$ ，样本的类间离差矩阵 $B = \sum_{j=1}^J (\bar{\mathbf{x}}^{(j)} - \bar{\mathbf{x}})(\bar{\mathbf{x}}^{(j)} - \bar{\mathbf{x}})^T$ ，样本的类内离差矩阵 $W = \sum_{j=1}^J \sum_{i=1}^{n_j} (\mathbf{x}_i^{(j)} - \bar{\mathbf{x}}^{(j)})(\mathbf{x}_i^{(j)} - \bar{\mathbf{x}}^{(j)})^T$ 。

$W^{-1}B$ 的单位正交特征向量为： $\hat{\boldsymbol{\xi}}_1^T, \hat{\boldsymbol{\xi}}_2^T, \dots, \hat{\boldsymbol{\xi}}_k^T$ ($k = 1, 2, \dots, \min(J-1, p)$, p 为多元正态维数，特征向量按特征值大小排列)。

记 $\bar{y}_k^{(j)} = \hat{\boldsymbol{\xi}}_k^T \bar{\mathbf{x}}^{(j)}$ ，对新预测点 $\mathbf{x}$ 来说， $\hat{y}_k = \hat{\boldsymbol{\xi}}_k^T \mathbf{x}$ ，则判别准则为使得下式最小的 j 就是预测总体：

$$\sum_{k=1}^{\min(J-1, p)} (\hat{y}_k - \bar{y}_k^{(j)})^2$$

10.10.2 实例

对下述三个总体的样本，试用 Fisher 样本判别函数对新的样本 $\mathbf{x}_0 = [1, 3]^T$

为简化计算，已算出两个特征向量分别为： $\hat{\boldsymbol{\xi}}_1 = (0.386, 0.495)^T, \hat{\boldsymbol{\xi}}_2 = (0.938, -0.112)^T$

$$\mathbf{X}^{(1)} = \begin{pmatrix} -2 & 5 \\ 0 & 3 \\ -1 & 1 \end{pmatrix}, \quad \mathbf{X}^{(2)} = \begin{pmatrix} 0 & 6 \\ 2 & 4 \\ 1 & 2 \end{pmatrix}, \quad \mathbf{X}^{(3)} = \begin{pmatrix} 1 & -2 \\ 0 & 0 \\ -1 & -4 \end{pmatrix}.$$

图 18: 多个总体的 Fisher 判别实例