

分层 & 等概率整群抽样作业

统计与数据科学学院 2112054 王赫明

1. 在下列情形下，你会选择什么分层变量？

- a. 一项政治民意测验，用于估计亚利桑那州有多大比重的选民对现在政府的工作持赞成态度；
- b. 学校对学生进行电话调查，用于估计学生在课本上花费的总金额；
- c. 抽取纽约市中学的样本，用于估计有多大比重的中学提供一门以上的计算机课程；
- d. 抽取加利福尼亚州公共图书馆的样本，用于研究计算机资源的利用情况及相应的人均消费；
- e. 抽取关于淡水湖边钓鱼者的样本，调查哪一种鱼最受欢迎；
- f. 进行一次空中调查，用于估计东经 173° 和西经 154° 间阿拉斯加附近浮冰块上面的海象数目；
- g. 哥伦比亚广播公司 (CBS) 黄金时段 (周一至周六晚上 7:00 到 10:00, 周日晚上 6:00 到 10:00) 电视节目的调查，用于估计平均每小时的广告数目。

Answer:

- a. 可以选择**选民的党派倾向、政治信仰或年龄**等因素作为分层变量。
- b. 可以选择**学生的成绩，年级，经济水平**等因素作为分层变量。
- c. 可以选择**学校所在地区、学校教学水平，学生人数规模**等因素作为分层变量。
- d. 可以选择**图书馆所在城市的人口密度、图书馆的规模或图书馆的服务水平**等因素作为分层变量。
- e. 可以选择**湖的大小，钓鱼者的垂钓位置，时间**等因素作为分层变量。
- f. 可以选择**浮冰块的大小、位置**等因素作为分层变量。
- g. 可以选择**观众的年龄、性别或收入水平**等因素作为分层变量。

2. 假设一个城市中共有 90000 户住所，其中 35000 户为独立建筑、45000 户为楼房单元、10000 户为共管房。已知独立建筑的平均用电量大约为楼房单元或者共管房的两倍，并且标准差与其均值成比例。如果要估计该城市中所有住户的平均用电量，应该将有 900 个观测单元的样本如何分配？

根据 Neyman 分配公式：

$$n_h = n \frac{W_h S_h}{\sum_{h=1}^L W_h S_h} = n \frac{N_h S_h}{\sum_{h=1}^L N_h S_h} \quad (1)$$

对于本问：

独立建筑 $N_1=35000$ ；楼房单元 $N_2=45000$ ；共管房 $N_3=10000$ 。

由已知倍数信息，方差有如下关系：

独立建筑 $S_1=2s$ ；楼房单元 $S_2=s$ ；共管房 $S_3=s$ 。

代入 Neyman 计算得：

独立建筑 $n_1=504$ ；

楼房单元 $n_2=324$ ；

共管房 $n_3=72$ 。

3. Senturia 等 (1994) 介绍了一项为研究有多少儿童在家里能够接触到枪支的调查。问卷发放对象是最近一周时间内因为健康原因或患病儿童而去过 Chicago(芝加哥) 地区被选定诊所的所有家长。

a. 假设感兴趣的变量是有枪支家庭的百分比。说明这为什么是一个整群样本？PSU 是什么？SSU 呢？它是 1 阶还是 2 阶整群样本？你将怎样估计有枪支家庭的百分比、以及此估计的标准误？

Answer:

a. 这是一个整群样本，因为调查对象是所有去过芝加哥地区被选定诊所的家长，而我们感兴趣的是芝加哥地区的家庭是否有枪支，并没有直接抽取儿童或家庭。

在这个调查中，PSU 即为被选定的诊所，SSU 即为被调查的家长。

这是一个一阶整群样本，因为只有一级抽样单元（诊所）和二级抽样单元（家长），在抽取某诊所后会调查与之相关的所有家长，而非再对诊所里的家长进行二次抽样。

要估计有枪支家庭的百分比，可以采用估计方法。作约定记号如下：N 为该地区医院总数，n 为抽取的医院数， $f=n/N$ 。 M_i 为去过第 i 家医院的家长总数， y_i 为去过第 i 家医院的家长中，儿童接触过枪支的家庭总数。可将其表示为示性函数的加和形式：

$$y_i = \sum_{k=1}^{M_i} I_{\{\text{The } k\text{-th parent's child has been exposed to firearms}\}} \quad (2)$$

则该比例的估计值可以表示为：

$$\bar{y}_{ratio} = \frac{\sum_{i=1}^n y_i}{\sum_{i=1}^n M_i} \quad (3)$$

标准误可由下面的公式计算得到：

$$\bar{m} = \frac{\sum_{i=1}^n M_i}{n} \quad (4)$$

$$v(\bar{y}_{ratio}) = \frac{1-f}{n\bar{m}^2} \frac{\sum_{i=1}^n (y_i - \bar{y}_{ratio})^2}{n-1} \quad (5)$$

$$SE(\bar{y}_{ratio}) = \sqrt{v(\bar{y}_{ratio})} \quad (6)$$

b. 此研究的抽样总体是什么？你认为这一抽样过程可以得到有儿童家庭的代表性样本吗？为什么？

抽样总体是那些儿童因患病等原因而在一周内访问过医院的家庭；

该抽样过程具有一定误差，因为接触过枪支的儿童可能不会在这一周内去过医院，估计值可能会小于真实值。

4. 一家会计机构想要估计一下它正进行的一项税务审计的误差率。总体包括了 828 项凭证，该机构要审计其中的一个含有 85 项凭证的简单随机样本。这 85 项入样凭证中，每项都有 215 处可供检查是否存在误差。有 1 项凭证在 215 处中有 4 处误差，1 项凭证有 3 处误差，4 项凭证有 2 处误差，22 项凭证有 1 处误差，其余 57 项凭证没有误差。

a. 将凭证作为 PSU，凭证中各处的观测作为 SSU，估计所有 828 项凭证的误差率，并给出该估计的标准误。

该问中，取 $N=828, n=85, M=215, f=85/828$ 。

在 85 个 PSU 中，用 $\bar{y}_i$ 表示第 i 个凭证中的误差率。根据题干数据， $\bar{y}_i = 0$ 的样本共有 57 个， $\bar{y}_i = 1/215$ 的样本共有 22 个， $\bar{y}_i = 2/215$ 的样本共有 4 个， $\bar{y}_i = 3/215$ 的样本共有 1 个， $\bar{y}_i = 4/215$ 的样本共有 1 个。

得到总误差率的估计值：

$$\bar{\bar{y}} = \frac{\sum_{i=1}^n \bar{y}_i}{n} \approx 0.002025 \quad (7)$$

再计算该估计的标准误：

$$s_b^2 = \frac{M}{n-1} \sum_{i=1}^n (\bar{y}_i - \bar{\bar{y}})^2 \quad (8)$$

$$v(\bar{\bar{y}}) = \frac{1-f}{nM} s_b^2 \approx 1.275 * 10^{-7} \quad (9)$$

$$SE(\bar{\bar{y}}) = \sqrt{v(\bar{\bar{y}})} \approx 3.571 * 10^{-3} \quad (10)$$

b. 估计 828 项凭证中误差的总数量及其标准误.

误差总量估计：

$$\hat{y} = NM\bar{\bar{y}} \approx 360 \quad (11)$$

标准误：

$$SE(\hat{y}) = NMSE(\bar{\bar{y}}) \approx 63.57 \quad (12)$$

c. 假定从总体的 178020 处中抽取了 85x215=18275 处的简单随机样本、而非整群样本。如果由简单随机样本得到的误差率估计值与 (a) 部分相同，那么估计方差 $V(p_srs)$ 会是多少？与 (a) 部分的估计方差相比会怎样？

该问中，不再有 PSU,SSU 的区分，每一处可能出现误差的地方就是一个样本，此时 y_i 的取值非 0 即 1。具体的计算式使用 SRS 中的公式即可。注意这时候样本数为 $nM=17825$ 。

$$\bar{y}_{SRS} = \bar{\bar{y}} \approx 0.002025 \quad (13)$$

$$V(p_srs) = v(p_srs) = \frac{1-f}{Mn} s_{SRS}^2 = \frac{1-f}{Mn} \frac{\sum_{i=1}^{Mn} (y_i - \bar{\bar{y}})^2}{Mn-1} \approx 9.922 * 10^{-8} \quad (14)$$

$9.922 * 10^{-8} < 1.275 * 10^{-7}$ 显然，SRS 得到的方差要小于整群抽样得到的方差。可能因为简单随机样本具有更大的抽样误差，样本中不同凭证的误差率可能有较大差异，因此估计方差会相对较小。