

# 数据采集方法 不等概抽样作业

统计与数据科学学院 2112054 王赫明

1. 文件 statepps.data 里列有 50 个州加上哥伦比亚地区的县郡数量，陆地面积，以及 1992 年人口数。

(a) 使用累计规模方法（即代码法），根据与陆地面积成正比的概率，抽取 10 次，得到一个样本。一次抽取中每个州的人样概率是多少？

以陆地面积（landarea）作为规模，使用代码法抽取  $[1, \text{max\_area}]$  的随机数，按数据集中累积面积（cumarea）确定随机数所处区间，从而确定抽取的州名。

抽样结果如下：

|    | Random number | State      | Area   | Probability |
|----|---------------|------------|--------|-------------|
| 35 | 2539645       | Ohio       | 40953  | 0.011581    |
| 1  | 281271        | Alaska     | 570374 | 0.161292    |
| 27 | 2084245       | Nebraska   | 76878  | 0.021740    |
| 3  | 744689        | Arkansas   | 52075  | 0.014726    |
| 50 | 3522465       | Wyoming    | 97105  | 0.027460    |
| 12 | 1206763       | Idaho      | 82751  | 0.023401    |
| 1  | 589117        | Alaska     | 570374 | 0.161292    |
| 4  | 854264        | California | 155973 | 0.044107    |
| 1  | 202392        | Alaska     | 570374 | 0.161292    |
| 28 | 2104189       | Nevada     | 109806 | 0.031051    |

图 1: 按面积 PPS

(b) 使用累计规模方法，根据与人口数成正比的概率，抽取 10 次，得到一个样本。一次抽取中每个州的人样概率是多少？

以人口数 (popn) 作为规模，使用代码法抽取  $[1, \max\_popn]$  的随机数，按数据集中累积人口 (cumpopn) 确定随机数所处区间，从而确定抽取的洲名。

抽样结果如下：

|    | Random number | State         | Popn     | Probability |
|----|---------------|---------------|----------|-------------|
| 43 | 227805979     | Texas         | 17682538 | 0.069322    |
| 28 | 139596049     | Nevada        | 1336000  | 0.005238    |
| 29 | 140689439     | New Hampshire | 1115087  | 0.004372    |
| 35 | 177553525     | Ohio          | 11021419 | 0.043208    |
| 25 | 135626610     | Missouri      | 5190719  | 0.020350    |
| 43 | 224461109     | Texas         | 17682538 | 0.069322    |
| 14 | 87842414      | Indiana       | 5658323  | 0.022183    |
| 35 | 178797884     | Ohio          | 11021419 | 0.043208    |
| 5  | 43129024      | Colorado      | 3464675  | 0.013583    |
| 22 | 119236015     | Michigan      | 9433665  | 0.036984    |

图 2: 按人口 PPS

(c) 这两个样本有何不同？每个样本中，哪些州更可能被抽到？

两样本作 PPS 采用不同的规模度量。(a) 问以每个洲的陆地面积为规模，(b) 问以每个洲的人口数量为规模。

下面的表格统计出了两种 PPS 方式中各自规模最大的五个洲：

|    | state      | counties | cumcount | landarea | cumland | popn     | cumpopn   |
|----|------------|----------|----------|----------|---------|----------|-----------|
| 1  | Alaska     | 25       | 92       | 570374   | 621124  | 587766   | 4725277   |
| 43 | Texas      | 254      | 2774     | 261914   | 3163179 | 17682538 | 233891081 |
| 4  | California | 58       | 240      | 155973   | 942814  | 30895356 | 41847254  |
| 26 | Montana    | 57       | 1650     | 145556   | 2013165 | 822347   | 137643492 |
| 31 | New Mexico | 33       | 1825     | 121365   | 2337602 | 1581830  | 151097193 |

图 3: 按面积 PPS

|    | state        | counties | cumcount | landarea | cumland | popn     | cumpopn   |
|----|--------------|----------|----------|----------|---------|----------|-----------|
| 4  | California   | 58       | 240      | 155973   | 942814  | 30895356 | 41847254  |
| 32 | New York     | 62       | 1887     | 47224    | 2384826 | 18109491 | 169206684 |
| 43 | Texas        | 254      | 2774     | 261914   | 3163179 | 17682538 | 233891081 |
| 9  | Florida      | 67       | 382      | 53937    | 1107341 | 13482716 | 63349866  |
| 38 | Pennsylvania | 67       | 2308     | 44820    | 2752993 | 11995405 | 205870673 |

图 4: 按人口 PPS

根据抽样结果，这些规模最大的洲确实抽取概率要高于其他洲。

(d) 利用根据与人口数成正比的概率抽样得到的样本，估计美国的县郡总数量，并计算估计标准误。

Hansen-Hurwitz 估计量：

$$\hat{Y}_{HH} = \frac{1}{n} \sum_{i=1}^n \frac{y_i}{Z_i} \quad (1)$$

由于本问采用的是 PPS 抽样，有  $Z_i = \frac{M_i}{M_0}$ ，故可改写上式为：

$$\hat{Y}_{HH} = \frac{M_0}{n} \sum_{i=1}^n \frac{y_i}{M_i} \quad (2)$$

对于该估计量  $\hat{Y}_{HH}$ ，其基于总体的真实方差为：

$$V[\hat{Y}_{HH}] = \frac{1}{n} \sum_{i=1}^n Z_i \left( \frac{Y_i}{Z_i} - Y \right)^2 \quad (3)$$

由样本得到的其无偏估计为：

$$v[\hat{Y}_{HH}] = \frac{1}{n(n-1)} \sum_{i=1}^n \left( \frac{y_i}{Z_i} - \hat{Y}_{HH} \right)^2 \quad (4)$$

在 PPS 下，将  $Z_i = \frac{M_i}{M_0}$  代入上式，最终计算式为：

$$v[\hat{Y}_{HH}] = \frac{M_0^2}{n(n-1)} \sum_{i=1}^n \left( \frac{y_i}{M_i} - \frac{\hat{Y}_{HH}}{M_0} \right)^2 \quad (5)$$

$$s[\hat{Y}_{HH}] = \sqrt{v[\hat{Y}_{HH}]} \quad (6)$$

带入数据计算，得到结果为：

通过该方法得到的全美县郡总数为： 3380.6579249816373  
 该估计方差的无偏估计为： 150972.84179458037  
 标准误为： 388.55223817986223

图 5: 按人口 PPS 估计结果

**(e) 假设你的同学刘亦菲不知道你是根据与人口数成比例的概率抽样，她利用样本中 10 个州的县郡数量，使用简单随机抽样的计算公式，估计出美国的县郡数量。其估计值和估计标准误是多少？结果和你的有何不同？你有什么话想对刘亦菲说（即觉得她的估计有什么问题）？**

对于简单随机抽样，总体的总值有如下的简单估计：

$$\hat{Y}_{SRS} = N\bar{y} = \frac{N}{n} \sum_{i=1}^n y_i \quad (7)$$

该估计的方差估计如下：

$$v[\hat{Y}_{SRS}] = N^2 \frac{1-f}{n(n-1)} \sum_{i=1}^n (y_i - \bar{y})^2 \quad (8)$$

$$s[\hat{Y}_{SRS}] = \sqrt{v[\hat{Y}_{SRS}]} \quad (9)$$

代入数据，计算结果如下：

通过PPS得到的全美县郡总数为： 5431.5  
 该估计量的方差估计为： 1488524.8166666667  
 该估计的标准误为： 1220.051153299183

图 6: SRS 估计结果

显然，该估计值偏大，且估计的方差与标准误相较于 PPS 均有增高。估计值偏大的原因是，PPS 抽样的得到的样本中，大规模的洲被抽取的概率更大，而人口多的洲的县郡一定也是偏多的，所以若当做 SRS 计算，全样本是等权重的，那么较多的“大规模”洲也会使 SRS 的计算结果更大一些。

同时，SRS 的估计更不准确，原因是 PPS 的抽样和计算过程都考虑了规模带给不同洲的权重大小有所差异，而 PPS 则没有充分利用这一辅助信息，估计的偏差相较于 PPS 较大也是合理的。

## 2.

某公司欲了解职工上班交通所需的时间，该公司共有 5 个部门，根据每个部门的人数采用 PPS 抽样抽出 2 个部门，并在 2 个部门中采用简单随机抽样分别抽出 5 名职工，调查结果如下：

| 部门 $i$ | 职工人数 $M_i$ | 时间 $y_{ij}$ (分钟)   |
|--------|------------|--------------------|
| 1      | 20         | 40, 10, 20, 30, 40 |
| 2      | 35         | 60, 30, 20, 60, 30 |

试估计该公司职工上班交通平均所需的时间，并计算估计的标准差。

这是一个两阶段放回的不等概抽样问题。第一阶段的 PSU 使用 PPS 方法进行抽样，得到的样本是自加权的；第二阶段的 SSU 则使用 SRS 方法进行抽样。

该问题的 PSU 是公司中的五个部门，SSU 是部门中员工的上班通勤时间。

一阶段的 PPS 以部门的职工人数作为规模，按权重进行不等概抽样。但并未给出总规模（全公司五个部门的总人数） $M_0$ ，因此无法对总值进行估计，只能估计总体的 SSU 均值  $\bar{y}$ 。

取  $n=2, m=5, \sum_{i=1}^n \sum_{j=1}^m y_{ij} = 340$

$$\hat{\bar{y}} = \frac{1}{nm} \sum_{i=1}^n \sum_{j=1}^m y_{ij} \quad (10)$$

$\bar{y}_1 = 28, \bar{y}_2 = 40$ , 该估计值的方差估计为：

$$v[\hat{\bar{y}}] = \frac{1}{n(n-1)} \sum_{i=1}^n (\bar{y}_i - \bar{\bar{y}})^2 \quad (11)$$

代入参数,  $\hat{\bar{y}} = 34, s(\hat{\bar{y}}) = \sqrt{v[\hat{\bar{y}}]} = \sqrt{36} = 6$