

预测分析 2026 Final 考试卷

Eurekaimer 2026 Spring

题目 1: Bias–Variance–Noise 分解与模型复杂度. 设真实数据生成模型为

$$Y = f(X) + \varepsilon,$$

其中

$$E(\varepsilon) = 0, \quad \text{Var}(\varepsilon) = \sigma^2.$$

给定一个学习算法。由于训练集是随机的，该算法在点 x 处得到的预测函数 $\hat{f}(x)$ 也是随机变量。

(1) 在平方损失下，推导 prediction error 的 bias、variance、noise 分解：

$$E \left[(Y - \hat{f}(x))^2 \right] = \text{Bias}^2(\hat{f}(x)) + \text{Var}(\hat{f}(x)) + \sigma^2.$$

请明确写出 bias 和 variance 的定义。

(2) 简述模型复杂度与 underfitting / overfitting 的关系。

解. (1) 令

$$\bar{f}(x) = E_{\mathcal{D}}[\hat{f}(x)],$$

定义

$$\begin{aligned} \text{Bias}(\hat{f}(x)) &= \bar{f}(x) - f(x), \\ \text{Var}(\hat{f}(x)) &= E_{\mathcal{D}} \left[(\hat{f}(x) - \bar{f}(x))^2 \right]. \end{aligned}$$

在固定 x 处，

$$Y = f(x) + \varepsilon.$$

先写成

$$Y - \hat{f}(x) = \{f(x) - \bar{f}(x)\} + \{\bar{f}(x) - \hat{f}(x)\} + \varepsilon.$$

因此有 3 个平方项和 3 个交叉项：

$$\begin{aligned} E \left[(Y - \hat{f}(x))^2 \right] &= E \left[\{f(x) - \bar{f}(x)\}^2 + \{\bar{f}(x) - \hat{f}(x)\}^2 + \varepsilon^2 \right. \\ &\quad + 2\{f(x) - \bar{f}(x)\}\{\bar{f}(x) - \hat{f}(x)\} \\ &\quad \left. + 2\{f(x) - \bar{f}(x)\}\varepsilon + 2\{\bar{f}(x) - \hat{f}(x)\}\varepsilon \right]. \end{aligned}$$

三个平方项为

$$E \left[\{f(x) - \bar{f}(x)\}^2 \right] = \text{Bias}^2(\hat{f}(x)),$$

$$E \left[\{\bar{f}(x) - \hat{f}(x)\}^2 \right] = \text{Var}(\hat{f}(x)),$$

$$E(\varepsilon^2) = \sigma^2.$$

三个交叉项为

$$E \left[\{f(x) - \bar{f}(x)\} \{\bar{f}(x) - \hat{f}(x)\} \right] = \{f(x) - \bar{f}(x)\} E[\bar{f}(x) - \hat{f}(x)] = 0,$$

$$E \left[\{f(x) - \bar{f}(x)\} \varepsilon \right] = \{f(x) - \bar{f}(x)\} E(\varepsilon) = 0,$$

$$E \left[\{\bar{f}(x) - \hat{f}(x)\} \varepsilon \right] = 0.$$

所以

$$E \left[(Y - \hat{f}(x))^2 \right] = \text{Bias}^2(\hat{f}(x)) + \text{Var}(\hat{f}(x)) + \sigma^2.$$

(2) 模型复杂度较低时, 模型表达能力不足, 通常 bias 较大、variance 较小, 容易 underfitting。随着模型复杂度增加, bias 通常下降, 但模型对训练集随机波动更敏感, variance 通常上升。noise 是数据本身的不可约误差, 不会因更换模型而消失。因此测试误差通常先下降后上升, 形成 U 型曲线; 复杂度过高时容易 overfitting。

题目 2: Gaussian Process 条件预测分布. 设 $Y(x)$ 是零均值 Gaussian Process, 其协方差函数为

$$C(x_1, x_2) = 4 \exp \{-(x_1 - x_2)^2\}.$$

已知观测点为 $x = 0$ 和 $x = 2$, 预测点为 $x_* = 1$ 。

(1) 若观测无噪声, 且

$$Y(0) = 2, \quad Y(2) = -2,$$

求预测点的分布。若题意为条件预测分布, 求

$$Y(1) \mid Y(0) = 2, Y(2) = -2.$$

若题意为边缘分布, 也写出对应结果。

(2) 若前面的观测受到独立高斯噪声干扰:

$$T(x_i) = Y(x_i) + \varepsilon_i, \quad \varepsilon_i \sim N(0, 1),$$

且

$$T(0) = 2, \quad T(2) = -2,$$

重新计算预测点的分布。若题意为条件预测分布, 求

$$Y(1) \mid T(0) = 2, T(2) = -2.$$

若题意为边缘分布, 也写出对应结果。

解. (1) 令

$$\mathbf{y} = \begin{pmatrix} Y(0) \\ Y(2) \end{pmatrix}, \quad y_* = Y(1).$$

由于 $Y(x)$ 是零均值 Gaussian Process,

$$\begin{pmatrix} \mathbf{y} \\ y_* \end{pmatrix} \sim N \left(0, \begin{pmatrix} K & k_* \\ k_*^T & C(1,1) \end{pmatrix} \right),$$

其中

$$K = \begin{pmatrix} C(0,0) & C(0,2) \\ C(2,0) & C(2,2) \end{pmatrix} = \begin{pmatrix} 4 & 4e^{-4} \\ 4e^{-4} & 4 \end{pmatrix},$$

$$k_* = \begin{pmatrix} C(0,1) \\ C(2,1) \end{pmatrix} = \begin{pmatrix} 4e^{-1} \\ 4e^{-1} \end{pmatrix}, \quad C(1,1) = 4.$$

高斯条件分布公式给出

$$Y(1) | \mathbf{y} \sim N(k_*^T K^{-1} \mathbf{y}, 4 - k_*^T K^{-1} k_*).$$

这里

$$\mathbf{y} = \begin{pmatrix} 2 \\ -2 \end{pmatrix}.$$

由于 k_* 两个分量相同, 而观测值为一正一负,

$$k_*^T K^{-1} \mathbf{y} = 0.$$

同时

$$k_*^T K^{-1} k_* = \frac{8e^{-2}}{1 + e^{-4}}.$$

因此

$$Y(1) | Y(0) = 2, Y(2) = -2 \sim N \left(0, 4 - \frac{8e^{-2}}{1 + e^{-4}} \right).$$

如果题目只是问 $Y(1)$ 的边缘分布, 不利用观测值, 则由零均值 GP 直接得到

$$Y(1) \sim N(0, C(1,1)) = N(0, 4).$$

(2) 现在观测的是

$$\mathbf{t} = \begin{pmatrix} T(0) \\ T(2) \end{pmatrix} = \begin{pmatrix} 2 \\ -2 \end{pmatrix}.$$

由于观测噪声方差为 1, 训练观测的协方差矩阵变为

$$K + I = \begin{pmatrix} 5 & 4e^{-4} \\ 4e^{-4} & 5 \end{pmatrix}.$$

预测点 $Y(1)$ 与观测 $\mathbf{t}$ 的交叉协方差仍为

$$k_* = \begin{pmatrix} 4e^{-1} \\ 4e^{-1} \end{pmatrix}.$$

所以

$$Y(1) | \mathbf{t} \sim N(k_*^T(K+I)^{-1}\mathbf{t}, 4 - k_*^T(K+I)^{-1}k_*).$$

同样因为 k_* 两个分量相同且 $\mathbf{t} = (2, -2)^T$,

$$k_*^T(K+I)^{-1}\mathbf{t} = 0.$$

而

$$k_*^T(K+I)^{-1}k_* = \frac{16e^{-2}(10 - 8e^{-4})}{25 - 16e^{-8}}.$$

因此

$$Y(1) | T(0) = 2, T(2) = -2 \sim N\left(0, 4 - \frac{16e^{-2}(10 - 8e^{-4})}{25 - 16e^{-8}}\right).$$

如果题目只是问潜在过程 $Y(1)$ 的边缘分布, 则仍然是

$$Y(1) \sim N(0, 4).$$

如果问的是未来带噪声观测 $T(1) = Y(1) + \varepsilon$ 的边缘分布, 则

$$T(1) \sim N(0, 5).$$

题目 3: Support Vector Machine 与 KKT 条件. 给定训练样本

$$\{(x_i, y_i)\}_{i=1}^N, \quad y_i \in \{-1, +1\}.$$

- (1) 写出 primal problem, 构造 Lagrangian, 并由 KKT 条件推导 dual problem。
- (2) 说明为什么最优分类边界只由训练样本中的一个子集决定。

解. (1) Primal problem:

$$\min_{w, b} \frac{1}{2} \|w\|^2,$$

subject to

$$y_i(w^T x_i + b) \geq 1, \quad i = 1, \dots, N.$$

等价地, 约束可写为

$$1 - y_i(w^T x_i + b) \leq 0.$$

引入 $\alpha_i \geq 0$, Lagrangian 为

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 + \sum_{i=1}^N \alpha_i [1 - y_i(w^T x_i + b)].$$

Stationarity:

$$\frac{\partial L}{\partial w} = w - \sum_{i=1}^N \alpha_i y_i x_i = 0,$$

所以

$$w = \sum_{i=1}^N \alpha_i y_i x_i.$$

同时

$$\frac{\partial L}{\partial b} = - \sum_{i=1}^N \alpha_i y_i = 0,$$

所以

$$\sum_{i=1}^N \alpha_i y_i = 0.$$

代回 Lagrangian, 得到 dual problem:

$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j x_i^T x_j,$$

subject to

$$\begin{aligned} \alpha_i &\geq 0, \quad i = 1, \dots, N, \\ \sum_{i=1}^N \alpha_i y_i &= 0. \end{aligned}$$

KKT 条件还包括

$$\begin{aligned} y_i(w^T x_i + b) &\geq 1, \\ \alpha_i &\geq 0, \\ \alpha_i [1 - y_i(w^T x_i + b)] &= 0. \end{aligned}$$

(2) 由 KKT 条件可知

$$w = \sum_{i=1}^N \alpha_i y_i x_i.$$

分类函数可写为

$$f(x) = w^T x + b = \sum_{i=1}^N \alpha_i y_i x_i^T x + b.$$

因此只有 $\alpha_i > 0$ 的样本点会出现在 w 和 $f(x)$ 中。若 $\alpha_i = 0$, 该样本对分类边界没有直接贡献。

由 complementary slackness,

$$\alpha_i [1 - y_i(w^T x_i + b)] = 0.$$

当 $\alpha_i > 0$ 时,

$$y_i(w^T x_i + b) = 1.$$

这些点称为支持向量。最优分类边界只由这些 $\alpha_i > 0$ 的样本点决定。

题目 4: 混合 Bernoulli 模型与 EM 算法. 给定 N 个 D 维二元观测

$$x_n = (x_{n1}, \dots, x_{nD}), \quad x_{nd} \in \{0, 1\}.$$

假设样本来自两个 Bernoulli product distributions 的混合模型:

$$p(x_n | \pi, \mu_1, \mu_2) = \pi \prod_{d=1}^D \mu_{1d}^{x_{nd}} (1 - \mu_{1d})^{1-x_{nd}} \\ + (1 - \pi) \prod_{d=1}^D \mu_{2d}^{x_{nd}} (1 - \mu_{2d})^{1-x_{nd}}.$$

引入 one-hot 隐变量

$$z_n = (z_{n1}, z_{n2})^T, \quad z_{nk} \in \{0, 1\}, \quad z_{n1} + z_{n2} = 1.$$

记

$$\pi_1 = \pi, \quad \pi_2 = 1 - \pi.$$

(1) 写出 complete-data log-likelihood

$$\log p(X, Z | \pi, \mu_1, \mu_2).$$

(2) 使用 EM 算法推导参数 π 和 μ_{kd} 的更新公式。

解. (1) 记

$$B_k(x_n) = \prod_{d=1}^D \mu_{kd}^{x_{nd}} (1 - \mu_{kd})^{1-x_{nd}}, \quad k = 1, 2.$$

在给定隐变量 Z 后,

$$p(X, Z | \pi, \mu_1, \mu_2) = \prod_{n=1}^N \prod_{k=1}^2 [\pi_k B_k(x_n)]^{z_{nk}}.$$

因此 complete-data log-likelihood 为

$$\log p(X, Z | \pi, \mu_1, \mu_2) = \sum_{n=1}^N \sum_{k=1}^2 z_{nk} \left[\log \pi_k + \sum_{d=1}^D \{x_{nd} \log \mu_{kd} + (1 - x_{nd}) \log(1 - \mu_{kd})\} \right].$$

(2) E-step 计算 responsibility:

$$\gamma_{nk} = p(z_{nk} = 1 | x_n) = \frac{\pi_k B_k(x_n)}{\pi_1 B_1(x_n) + \pi_2 B_2(x_n)}.$$

M-step 最大化

$$Q(\pi, \mu) = \sum_{n=1}^N \sum_{k=1}^2 \gamma_{nk} \left[\log \pi_k + \sum_{d=1}^D \{x_{nd} \log \mu_{kd} + (1 - x_{nd}) \log(1 - \mu_{kd})\} \right].$$

令

$$N_k = \sum_{n=1}^N \gamma_{nk}.$$

对 mixing proportion,

$$\pi_k^{\text{new}} = \frac{N_k}{N}, \quad k = 1, 2.$$

所以

$$\pi^{\text{new}} = \pi_1^{\text{new}} = \frac{1}{N} \sum_{n=1}^N \gamma_{n1}.$$

对 Bernoulli 参数,

$$\mu_{kd}^{\text{new}} = \frac{\sum_{n=1}^N \gamma_{nk} x_{nd}}{N_k}, \quad k = 1, 2, \quad d = 1, \dots, D.$$

题目 5: KL 散度、ELBO 与 Mean-field 变分推断. 设 X 为观测变量, Z 为隐变量, 联合分布为 $p(X, Z)$ 。令 $q(Z)$ 为任意关于隐变量的分布。

(1) 证明

$$\log p(X) = \mathcal{L}(q) + \text{KL}(q(Z) \| p(Z | X)),$$

其中

$$\mathcal{L}(q) = \int q(Z) \log \frac{p(X, Z)}{q(Z)} dZ.$$

(2) 设 mean-field 假设为

$$q(Z) = \prod_{j=1}^M q_j(Z_j).$$

证明最优 q_j 满足

$$\log q_j^*(Z_j) = E_{i \neq j} [\log p(X, Z)] + \text{constant},$$

等价于

$$q_j^*(Z_j) \propto \exp \{E_{i \neq j} [\log p(X, Z)]\}.$$

解. (1) 由 Bayes 公式,

$$p(Z | X) = \frac{p(X, Z)}{p(X)}.$$

于是

$$\begin{aligned} \text{KL}(q(Z) \| p(Z | X)) &= \int q(Z) \log \frac{q(Z)}{p(Z | X)} dZ \\ &= \int q(Z) \log \frac{q(Z)p(X)}{p(X, Z)} dZ \\ &= \int q(Z) \log q(Z) dZ + \log p(X) - \int q(Z) \log p(X, Z) dZ \\ &= \log p(X) - \int q(Z) \log \frac{p(X, Z)}{q(Z)} dZ \\ &= \log p(X) - \mathcal{L}(q). \end{aligned}$$

所以

$$\log p(X) = \mathcal{L}(q) + \text{KL}(q(Z) \| p(Z | X)).$$

(2) 从 ELBO 出发:

$$\mathcal{L}(q) = \int q(Z) \log p(X, Z) dZ - \int q(Z) \log q(Z) dZ.$$

在 mean-field 假设下,

$$q(Z) = q_j(Z_j) \prod_{i \neq j} q_i(Z_i),$$

且

$$\log q(Z) = \sum_{i=1}^M \log q_i(Z_i).$$

固定所有 q_i , $i \neq j$, 只优化 q_j 。与 q_j 有关的部分为

$$\mathcal{L}(q_j) = \int q_j(Z_j) E_{i \neq j} [\log p(X, Z)] dZ_j - \int q_j(Z_j) \log q_j(Z_j) dZ_j + \text{constant}.$$

其中 $E_{i \neq j}$ 表示对 $\prod_{i \neq j} q_i(Z_i)$ 取期望。

加入归一化约束

$$\int q_j(Z_j) dZ_j = 1.$$

构造泛函

$$\mathcal{J}(q_j) = \mathcal{L}(q_j) + \lambda \left(\int q_j(Z_j) dZ_j - 1 \right).$$

对 $q_j(Z_j)$ 作变分并令导数为零:

$$E_{i \neq j} [\log p(X, Z)] - \log q_j(Z_j) - 1 + \lambda = 0.$$

因此

$$\log q_j^*(Z_j) = E_{i \neq j} [\log p(X, Z)] + \text{constant}.$$

等价地,

$$q_j^*(Z_j) \propto \exp \{ E_{i \neq j} [\log p(X, Z)] \}.$$